



UNIVERSITÀ
DEGLI STUDI
DI TRIESTE

UNIVERSITÀ DEGLI STUDI DI TRIESTE

DIPARTIMENTO DI MATEMATICA, INFORMATICA
E GEOSCIENZE - MIGE

Corso di Laurea Triennale in
Artificial Intelligence and Data Analytics

TESI DI LAUREA TRIENNALE

Un nuovo modello in “Behavioral Epidemiology of Infectious Diseases”: il modello SIRS con distanziamento sociale

LAUREANDO:
Enrico Savorgnan
SM32 01371

RELATORE:
Prof. Alberto d’Onofrio

ANNO ACCADEMICO 2024 – 2025

“To strive, to seek, to find, and not to yield.”

Ulysses, Lord Alfred Tennyson

Indice

Indice	i
1 Introduzione	1
2 Modelli matematici in epidemiologia	3
2.1 Il modello SIR	3
2.2 Varianti e modello SIRS	5
2.2.1 Alcune importanti varianti	5
2.2.2 Modello SIRS	6
2.3 Studio del modello SIRS	6
2.3.1 Tempi relativamente piccoli: outbreak epidemi- ci di tipo SIRS	7
2.3.2 Caso generale: modello SIRS con dinamica vitale	10
3 L'Epidemiologia Comportamentale delle malattie infettive	16
3.1 Introduzione	16
3.2 La memoria in epidemiologia	17
3.3 Il modello SIR con distanziamento sociale	20
4 Impatto del comportamento umano sulla dinamica del mo- dello SIRS	24
4.1 Introduzione	24
4.2 Caso senza memoria	24
4.3 1 layer di memoria	27
4.4 2 layer di memoria	31
4.5 Memoria di tipo <i>incidence-based</i>	35
4.6 Caso senza dinamica vitale	38
5 Simulazioni dinamiche e biforcazioni numeriche	40
5.1 Introduzione	40

5.2	Impatto del distanziamento sociale	41
5.3	Confronto tra informazione prevalence-based e informazione incidence-based	46
6	Esplorazione dei metodi di ricostruzione neurale applicati al modello SIRS	49
6.1	Il problema della ricostruzione dei sistemi dinamici . .	49
6.2	I principali metodi di ricostruzione dei sistemi dinamici	50
6.2.1	Residual Networks	50
6.2.2	Neural Ordinary Differential Equations	51
6.2.3	Universal Differential Equations	52
6.3	Ricostruzione del modello SIRS	52
7	Discussione e sviluppi futuri	58
	Bibliografia	60

Capitolo 1

Introduzione

La presente Tesi di Ricerca, anche se per Laurea Triennale, nasce con due intenti principali.

Il primo intento è di illustrare e studiare, attraverso gli strumenti della matematica applicata, lo sviluppo e la diffusione di epidemie all'interno di una popolazione, nel caso in cui l'immunità legata alla guarigione dalla malattia non sia permanente.

Nel primo capitolo, dopo aver brevemente ricapitolato le proprietà dinamiche e di equilibrio del classico modello SIR, si analizza nel dettaglio il modello SIRS, più propriamente indicato per le numerose malattie infettive in cui l'immunità non è permanente.

Grande rilievo è stato posto nel successivo capitolo ai concetti dell'epidemiologia comportamentale, ovvero allo studio di come l'agire di singoli soggetti possa avere un impatto anche notevole riguardo al diffondersi dell'epidemia e al suo controllo.

Il secondo e principale intento della presente tesi è quello di proporre dei **nuovi modelli matematici** sul come l'adozione volontaria di misure di “distanziamento sociale”, dipendenti adattivamente dalla dinamica della propagazione di una malattia infettiva con immunità non permanente, ossia di tipo SIRS, abbia la capacità di modificare la dinamica di un'epidemia, ma non di estinguerla.

A questo fine viene dedicato il corpo centrale della presente tesi, attraverso una iniziale panoramica della letteratura in merito, un successivo studio analitico dei modelli SIRS presentati e un terzo capitolo

dedicato alle numerose simulazioni numeriche svolte per confermare le intuizioni iniziali.

Infine, verrà proposta una prima applicazione in ambito epidemiologico di architetture proprie del machine learning quali Residual Networks, Neural Ordinary Differential Equations e Universal Differential Equations, al fine di ricostruire i modelli presentati.

La Tesi è conclusa da un breve capitolo in cui si riassumeranno le innovazioni e i risultati proposti nella tesi, e si illustreranno alcuni possibili sviluppi.

La Tesi costituisce il cuore di un manoscritto scientifico, attualmente in preparazione, che sarà a breve sottomesso a una rivista scientifica internazionale di classe Q1.

Capitolo 2

Modelli matematici in epidemiologia

2.1 Il modello SIR

Nell'epidemiologia moderna delle Malattie Infettive il modello SIR (Susceptible - Infected - Recovered) rappresenta il primo [1] [2], e più semplice modo per studiare la diffusione di un'epidemia all'interno di una popolazione, e può essere espresso attraverso tre semplici equazioni differenziali ordinarie.

Il nome del modello è l'acronimo delle tre classi in cui la popolazione viene suddivisa: Suscettibili, Infetti, Rimossi (in inglese: Recovered). Nella prima classe rientrano gli individui che, non avendo ancora contratto la malattia, sono ad essa esposti e possono quindi ammalarsi. La seconda classe è invece composta dagli individui che sono effettivamente contagiati e sono in grado di trasmettere l'infezione ad altre persone. Infine, nella terza classe rientrano gli individui che, guariti dalla malattia¹, non possono nuovamente contrarla poiché hanno sviluppato una resistenza immunitaria perenne alla malattia.

Il modello può essere graficamente rappresentato nel seguente modo: dove μ , β , γ sono parametri del modello, indicanti rispettivamente il tasso di mortalità, il tasso di infezione ed il tasso di guarigione, ed S , I , R le tre classi in cui la popolazione è suddivisa.

Prima di scrivere le equazioni del modello è necessario fare alcune assunzioni, alcune delle quali, come quasi sempre accade in ogni campo

¹più in generale, soggetti che hanno finito la fase infettiva. Difatti in talune malattie infettive, come la varicella, si è contagiosi prima di sviluppare i sintomi.

nella modellistica matematica, molto forti ma necessarie per semplificare lo studio.

Innanzitutto in questo modello e nei successivi viene sempre supposto che la malattia non induca morti dovute ad essa. Questo significa che le morti nella popolazione non sono mai riconducibili all'infezione, e che quindi non ci sia un extra-tasso di mortalità dovuto alla malattia. In secondo luogo, si suppone che il tasso di natalità e di mortalità all'interno della popolazione totale sia il medesimo. Questo implica che la numerosità della popolazione è costante. Di conseguenza

$$S + I + R = N,$$

dove N è la numerosità della popolazione e S, I, R la numerosità all'interno delle classi rispettivamente S, I, R.

Per semplicità notazionale normalizziamo la popolazione in modo che $N = 1^2$. Questo significa che S, I e R rappresentano le frazioni di Suscettibili, Infettivi e Rimossi.

Viene inoltre supposta l'assenza di nati malati, e quindi che il contagio non si possa trasmettere '*verticalmente*' [3] da madre infettiva a figlio. Infine, in questo modello si suppone che i tassi di infezione β e di guarigione γ siano costanti. Nei capitoli sulla epidemiologia comportamentale, invece, β sarà supposto essere dinamicamente variabile in funzione del numero di infetti.

Fatte queste necessarie premesse, possiamo scrivere il modello SIR come segue:

$$\frac{dS}{dt} = \mu - \mu S - \beta IS \quad (2.1)$$

$$\frac{dI}{dt} = \beta IS - \mu I - \gamma I \quad (2.2)$$

$$\frac{dR}{dt} = \gamma I - \mu R, \quad (2.3)$$

dove t è la variabile indipendente del *tempo*.

Si noti come una delle tre equazioni sia superflua, in quanto si può

²Tale normalizzazione non modifica i risultati ottenuti in questa Tesi. Tuttavia, utilizzare la popolazione normalizzata ha senso se i contagi sono indipendenti dalle dimensioni della popolazione, ovvero in casi di patogeni virali, mentre l'uso del generico $S+I+R = N$ è più propriamente indicato per epidemie legate ad animali e vegetali [3, 4, 5]

sempre scrivere una delle classi come differenza tra la popolazione totale e la somma delle altre due. Qui e altrove si analizzerà il modello dato dalle due equazioni differenziali per gli Infetti e per i Rimossi:

$$\frac{dI}{dt} = \beta I(1 - R - I) - I(\mu + \gamma) \quad (2.4)$$

$$\frac{dR}{dt} = \gamma I - R(\mu + \theta) \quad (2.5)$$

2.2 Varianti e modello SIRS

Il modello SIR, pur nella sua semplicità, è in grado di spiegare con buona approssimazione la dinamica della diffusione di molte malattie. Tuttavia, in qualche circostanza, è necessario modificare le sue equazioni per adattarle a nuove situazioni.

2.2.1 Alcune importanti varianti

In questa sezione illustriamo brevemente alcune importanti varianti del modello SIR, atte a meglio descrivere la diffusione di alcune malattie.

Un primo e importante esempio è dato dal modello SEIR (Susceptible - Exposed - Infected - Recovered), che introduce una nuova classe all'interno della popolazione in cui includere gli individui che, pur avendo contratto il virus, non sono ancora in grado di infettare altre persone. Questa situazione è tipica di alcune malattie, come per esempio la varicella e il morbillo, in cui il periodo di incubazione del virus è prolungato e pertanto il malato diventa contagioso ben dopo essere entrato in contatto con la malattia [6] [3].

Un secondo caso è costituito dai modelli SIRD (Susceptible-Infected-Recovered-Deceased) e SEIRD (Susceptible - Exposed - Infected - Recovered - Deceased), che tengono conto invece del tasso di mortalità dell'epidemia introducendo la nuova categoria dei Deceduti. Queste formulazioni dei modelli SIR e SEIR sono particolarmente indicate

per epidemie con una mortalità non trascurabile come, per esempio, la recente pandemia legata al virus SARS-CoV-2, almeno nelle sue fasi iniziali, o l'ebola.

Assieme al modello SEIR, una dei più importanti sviluppi del modello SIR è il modello SIRS.

2.2.2 Modello SIRS

Il terzo esempio, che è anche oggetto di uno studio più approfondito e di una estensione in questa tesi, è il modello SIRS: Susceptible-Infected-Recovered-Susceptible. Esso è indicato per analizzare la diffusione di malattie infettive in cui, come già anticipato precedentemente, l'immunità legata alla guarigione dalla malattia non è permanente, ma viene persa con un tasso indicato dal parametro θ .

Questo modello può essere quindi così scritto:

$$\dot{S} = \mu - \mu S - \beta IS + \theta R \quad (2.6)$$

$$\dot{I} = \beta IS - I(\mu + \gamma) \quad (2.7)$$

$$\dot{R} = \gamma I - R(\mu + \theta) \quad (2.8)$$

, dove con la notazione $\dot{\cdot}$ si indica qui e in seguito la derivata della variabile rispetto al tempo.

2.3 Studio del modello SIRS

Per studiare il modello SIRS si è ricorso sia all'analisi matematica ove possibile, sia, in casi più complessi, a simulazioni matematiche usando come software il linguaggio di programmazione Python 3.12, la libreria di calcolo scientifico Scipy 1.15.2, ed in particolare il suo modulo `scipy.integrate.solve_ivp`.

Un concetto necessario per lo studio dei modelli matematici, e cardine in epidemiologia, è l'ottenimento dei **punti di equilibrio**, valori tali per cui le equazioni differenziali del modello sono pari a 0.

Di conseguenza, i punti di equilibrio sono valori per cui, se raggiunti, il modello non varia nel tempo a meno di perturbazioni. In base al loro comportamento, questi punti vengono classificati in *stabili*, quando il sistema, se perturbato, vi ritorna, oppure *instabili* (UNST), quando invece il sistema perturbato vi si allontana.

Si distinguono inoltre punti di equilibrio *localmente* (LAS) o *globalmente* (GAS) stabili. La differenza è che questi ultimi sono resistenti a perturbazioni anche molto ampie. Geometricamente si tratta di minimi locali e di minimi globali, mentre i punti instabili sono i massimi del sistema. Lo studio dei punti di equilibrio è fondamentale perché permette di conoscere e analizzare il comportamento dell'intero sistema.

Tendenzialmente nei modelli epidemiologici, come quelli fino ad ora presentati, vengono individuati due punti di equilibrio: il primo, definito **Disease Free Equilibrium** (*DFE*), è caratterizzato dall'assenza di infetti, ed è riconducibile a situazioni di assenza o di eliminazione della malattia dalla popolazione in studio; il secondo, chiamato **Endemic Equilibrium** (*EE*), determina situazioni in cui la malattia è permanentemente presente nella popolazione, ed è tipicamente un punto di equilibrio stabile per malattie infettive comuni come, ad esempio, l'influenza.

2.3.1 Tempi relativamente piccoli: outbreak epidemici di tipo SIRS

Un primo passo nell'analisi del modello SIRS consiste nello studio del modello per tempi molto brevi, qualche mese al massimo, quando la malattia viene introdotta nella popolazione.

Per questi tempi possiamo supporre che il numero di nati e di deceduti all'interno della popolazione sia trascurabile: poniamo quindi $\mu = 0$.

Il modello diviene così:

$$\dot{S} = \theta R - \beta IS \quad (2.9)$$

$$\dot{I} = \beta IS - \gamma I \quad (2.10)$$

$$\dot{R} = \gamma I - \theta R \quad (2.11)$$

Ricordando inoltre che $S = N - R - I$ la prima equazione può essere trascurata, e rimodulando le tre classi S , I , R come frazioni della popolazione totale (o, equivalentemente, ponendo $S + I + R = 1$), possiamo riscrivere il sistema come:

$$\dot{I} = \beta I(1 - I - R) - \gamma I \quad (2.12)$$

$$\dot{R} = \gamma I - \theta R \quad (2.13)$$

Studiando tempi piccoli immediatamente successivi all'introduzione della malattia, ha senso considerare come condizioni iniziali il vettore

$$(S_0, I_0, R_0) = (1 - \varepsilon, \varepsilon, 0),$$

con

$$\varepsilon \ll 1.$$

Dunque ha senso approssimare $R \approx 0$.

Per poter studiare lo sviluppo del modello è possibile maggiorare l'equazione 2.12 come

$$\dot{I} = I(\beta - \gamma) - \beta IR - \beta I^2 \leq I(\beta - \gamma) \quad (2.14)$$

e, studiando il nuovo sistema in cui si è posto $Z = I$

$$\begin{cases} \dot{Z} = Z(\beta - \gamma) \\ Z_0 = I_0 \end{cases} \quad (2.15)$$

,si ricava, con semplici calcoli differenziali, che

$$Z(t) = I_0 e^{(\beta - \gamma)t}.$$

Questa funzione ha due comportamenti possibili

$$\begin{cases} Z(t) \xrightarrow{t \rightarrow \infty} \infty, & \text{se } \frac{\beta}{\gamma} > 1 \\ Z(t) \xrightarrow{t \rightarrow \infty} 0, & \text{se } \frac{\beta}{\gamma} < 1 \end{cases}$$

ovvero, poiché

$$I(t) < Z(t),$$

se $\frac{\beta}{\gamma} < 1$, la malattia scompare.

Se invece $\frac{\beta}{\gamma} > 1$, il sistema vada verso un punto di equilibrio endemico,




Figura 2.3.1: Confronto tra diverse simulazioni per 12 mesi del modello SIRS ($\gamma = 0.5$, $\theta = 0.0042$, $\varepsilon = 0.01$ [7]). Pannello sinistro: $R_0 = 0.7$. Pannello destro: $R_0 = 2.2$. Si notino a sinistra la quasi immediata scomparsa della malattia e a destra l'iniziale *outbreak* del numero di infetti con un successivo assestamento verso una fase endemica.

come verificato anche dalle simulazioni.

Tuttavia, il raggiungimento di tale *EE* non è immediato, e quindi è più conveniente studiare questa circostanza tenendo in considerazione anche la mortalità nella popolazione.

In epidemiologia, la frazione $\frac{\beta}{\gamma}$ è la versione per $\mu \approx 0$ del **Basic Reproduction Number**, indicato col simbolo R_0 (che si pronuncia in inglese "R naught").

Questo parametro, che nella sua formulazione completa vale

$$R_0 = \frac{\beta}{\mu + \gamma}, \quad (2.16)$$

è fondamentale perché, come si evincerà nel prosieguo di questo testo, la stabilità dei punti di equilibrio dipende proprio da esso.

L'indice R_0 può essere inteso come il numero medio di persone che un individuo malato infetta. Infatti, se $\frac{1}{\mu + \gamma}$ è il periodo medio durante il quale un individuo è ammalato, e β è il numero medio di persone che

questo infetta per unità di tempo, allora il numero totale di individui da lui infettati sarà [8]:

$$\int_0^{\frac{1}{\mu+\gamma}} \beta dt = \frac{\beta}{\mu + \gamma} = R_0 \quad (2.17)$$

2.3.2 Caso generale: modello SIRS con dinamica vitale

Il caso generale per il modello SIRS consiste, fondamentalmente, nell'analisi del modello a lungo termine, ossia tenendo conto della dinamica vitale di nascita e morte, quindi con tutti i suoi parametri.

Analogamente a quanto fatto nella Sezione 2.3.1, possiamo supporre

$$S + I + R = N = 1,$$

e pertanto trascurare una delle tre equazioni del modello. Considerando

$$S = 1 - I - R$$

si ottiene il seguente sistema:

$$\begin{cases} \dot{I} = I(\beta(1 - I - R) - (\mu + \gamma)) \\ \dot{R} = \gamma I - R(\mu + \theta) \end{cases} \quad (2.18)$$

Per ottenere i punti di equilibrio (S_{eq}, I_{eq}, R_{eq}) , si pongono a 0 le due equazioni differenziali. Una prima soluzione, ovvia, è data da

$$DFE = (1, 0, 0).$$

Imponendo poi dalla seconda equazione

$$I_{eq} = \frac{\mu + \theta}{\gamma} R_{eq},$$

con semplici calcoli analitici, e ricordando che $R_0 = \frac{\beta}{\mu+\gamma}$, si ottiene anche l'equilibrio di coesistenza

$$\begin{aligned} EE &= (S_{eq}, I_{eq}, R_{eq}) \\ &= \left(\frac{1}{R_0}, \left(1 - \frac{1}{R_0}\right) \frac{\mu + \theta}{\mu + \gamma + \theta}, \left(1 - \frac{1}{R_0}\right) \frac{\gamma}{\mu + \gamma + \theta} \right). \end{aligned} \quad (2.19)$$

Si noti che l'equilibrio endemico EE ha senso solo nel caso in cui $R_0 > 0$.

Viceversa, infatti, $S_{eq} > 1$, mentre $I_{eq}, R_{eq} < 0$, e questo è chiaramente un assurdo.

Possiamo quindi immediatamente ipotizzare che il parametro cardine su cui si basa la stabilità dei punti sia effettivamente l'indice R_0 .

Per analizzare il comportamento dei punti di equilibrio del sistema si possono adottare diverse tecniche. La principale consiste nella linearizzazione del sistema perturbato.

Dato un generico sistema di equazioni differenziali per il vettore $\mathbf{X} \in \mathbb{R}^n$, con $\dot{\mathbf{X}} = f(\mathbf{X})$, $\mathbf{X}_e$ un suo generico punto di equilibrio e $\mathbf{u}(t)$ una anch'essa generica perturbazione applicata a $\mathbf{X}_e$, si riscrive il sistema

$$\frac{d\mathbf{X}(t)}{dt} = f(\mathbf{X}(t))$$

come:

$$\frac{d}{dt}(\mathbf{X}_e + \mathbf{u}(t)) = f(\mathbf{X}_e + \mathbf{u}(t)).$$

Linearizzando secondo Taylor al primo ordine, ricordando che per definizione di punto di equilibrio $f(\mathbf{X}_e) = 0$, e applicando semplici proprietà dell'operazione di derivazione, si giunge alla nuova equazione

$$\begin{aligned} \frac{d\mathbf{u}}{dt} &= f(\mathbf{X}_e) + \mathbf{J}(\mathbf{X}_e)\mathbf{u}(t) \\ &= \mathbf{J}(\mathbf{X}_e)\mathbf{u}(t), \end{aligned} \tag{2.20}$$

dove qui e successivamente si indica con $\mathbf{J}$ la matrice jacobiana del sistema, definita come:

$$\mathbf{J} = \begin{bmatrix} \frac{\partial X_1}{\partial X_1} & \frac{\partial X_1}{\partial X_2} & \cdots & \frac{\partial X_1}{\partial X_n} \\ \frac{\partial X_2}{\partial X_1} & \frac{\partial X_2}{\partial X_2} & \cdots & \frac{\partial X_2}{\partial X_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial X_n}{\partial X_1} & \frac{\partial X_n}{\partial X_2} & \cdots & \frac{\partial X_n}{\partial X_n} \end{bmatrix} \tag{2.21}$$

L'equazione 2.20 ha come semplice soluzione

$$\mathbf{u}(t) = u_0 e^{\mathbf{J}(\mathbf{X}_e)t}$$

Grazie a questo risultato si può ricondurre lo studio della stabilità dei punti di equilibrio del sistema allo studio del segno degli autovalori λ_i di $\mathbf{J}$ valutata in $\mathbf{X}_e$.

Linearizzando secondo Taylor l'esponenziale della matrice, e jordanizzando la stessa, si ricava dunque:

$$\begin{aligned}
e^{\mathbf{J}t} &= \sum_{n=0}^{\infty} \frac{\mathbf{J}^n t^n}{n!} \\
&= \sum_{n=0}^{\infty} \frac{t^n}{n!} (H \text{Diag}(\lambda_1, \lambda_2, \dots, \lambda_m) H^{-1})^n \\
&= \sum_{n=0}^{\infty} \frac{t^n}{n!} H \text{Diag}(\lambda_1^n, \lambda_2^n, \dots, \lambda_m^n) H^{-1} \\
&= H \left(\sum_{n=0}^{\infty} \frac{t^n}{n!} \text{Diag}(\lambda_1^n, \lambda_2^n, \dots, \lambda_m^n) \right) H^{-1} \\
&= H \text{Diag} \left(\sum_{n=0}^{\infty} \frac{t^n}{n!} \lambda_1^n, \sum_{n=0}^{\infty} \frac{t^n}{n!} \lambda_2^n, \dots, \sum_{n=0}^{\infty} \frac{t^n}{n!} \lambda_m^n \right) H^{-1} \\
&= H \text{Diag}(e^{\lambda_1 t}, e^{\lambda_2 t}, \dots, e^{\lambda_m t}) H^{-1} \tag{2.22}
\end{aligned}$$

Generalmente, gli autovalori $\lambda_i \in \mathbb{C}$. Pertanto, se

$$\exists \lambda_i : \Re(\lambda_i) > 0$$

allora la matrice $\mathbf{J}$ cresce all'aumentare del tempo e pertanto la perturbazione $\mathbf{u}(t) \xrightarrow{t \rightarrow +\infty} +\infty$: il punto di equilibrio $\mathbf{X}_e$ è instabile. Viceversa, se

$$\forall \lambda_i, \Re(\lambda_i) < 0$$

, allora la perturbazione $\mathbf{u}(t) \xrightarrow{t \rightarrow +\infty} 0$, tende cioè ad annullarsi, dunque il punto di equilibrio $\mathbf{X}_e$ è stabile.

Applicando questi concetti al sistema 2.18, derivandolo componente a componente si ottengono le seguenti equazioni:

$$\begin{cases} \frac{\partial \dot{I}}{\partial I} = \beta(1 - I_e - R_e) - (\mu + \gamma) - \beta I_e \\ \frac{\partial \dot{I}}{\partial R} = -\beta I_{eq} \\ \frac{\partial \dot{R}}{\partial I} = \gamma \\ \frac{\partial \dot{R}}{\partial R} = -(\mu + \theta) \end{cases} \quad (2.23)$$

, da cui la jacobiana $\mathbf{J}_{\text{SIRS}}$:

$$\mathbf{J}_{\text{SIRS}} = \begin{bmatrix} \beta S_e - (\mu + \gamma) - \beta I_{eq} & -\beta I_{eq} \\ \gamma & -(\mu + \theta) \end{bmatrix}. \quad (2.24)$$

Studio DFE Valutando $\mathbf{J}_{\text{SIRS}}$ nel DFE si ottiene:

$$\mathbf{J}_{\text{SIRS}} \Big|_{(1,0,0)} = \begin{bmatrix} \beta - (\mu + \gamma) & 0 \\ \gamma & (\mu + \theta) \end{bmatrix}$$

Supponendo ora di perturbare leggermente il punto di equilibrio con un'intensità (i, r) , e quindi di poter scrivere

$$(I, R) = (0, 0) + (i, r),$$

applicando il risultato ottenuto nell'equazione 2.20 si possono quindi studiare le equazioni differenziali delle perturbazioni:

$$\frac{di}{dt} = i(\beta - (\mu + \gamma)) \quad (2.25)$$

$$\frac{dr}{dt} = \gamma i - r(\mu + \theta) \quad (2.26)$$

e, risolvendo la 2.25, si ottiene $i(t) = i(0)e^{[\beta - (\mu + \gamma)]t}$, che chiaramente ha due comportamenti diversi per $R_0 < 1$, caso in cui il numero di infetti tende allo 0, e per $R_0 > 1$, caso in cui tende ad ∞ . Come si vedrà nel prossimo paragrafo, per $R_0 > 1$ il sistema tende all' EE .

Considerando il caso in cui $R_0 = 1$, invece, si può notare come

$$\dot{I} = -\beta R I - \beta I^2 \leq 0,$$

cosicché in questo caso

$$I(t) \xrightarrow{t \rightarrow \infty} 0.$$

Pertanto possiamo concludere che

$$\begin{cases} \text{DFE GAS} & \text{se } R_0 \leq 1 \\ \text{DFE UNST} & \text{se } R_0 > 1 \end{cases} \quad (2.27)$$

Studio EE Come si è visto, $S_e = \frac{1}{R_0} = \frac{\mu+\gamma}{\beta}$. Pertanto, all' EE , la $\mathbf{J}_{\text{SIRS}}$ può essere riscritta come

$$\begin{bmatrix} -\beta I_e & -\beta I_e \\ \gamma & -(\mu + \theta) \end{bmatrix}$$

L'equazione caratteristica di $\mathbf{J}_{\text{SIRS}}$ si può dunque esprimere come

$$(-\beta I_e - \lambda)(-(\mu + \theta) - \lambda) + \beta\gamma I_e = 0, \quad (2.28)$$

da cui si ricava la seguente equazione ordinaria di secondo grado per λ :

$$\lambda^2 + b\lambda + c = 0, \quad (2.29)$$

con

$$b = \beta I_e + (\mu + \theta) \quad (2.30)$$

$$c = \beta\gamma I_e + \beta I_e(\mu + \theta) \quad (2.31)$$

Con semplici passaggi si possono riscrivere più elegantemente la 2.30:

$$\begin{aligned} b &= \beta I_e + (\mu + \theta) \\ &= \beta(1 - \frac{1}{R_0})\frac{\mu + \theta}{\mu + \gamma + \theta} + (\mu + \theta) \\ &= (\mu + \theta)\left(\frac{\beta}{\mu + \gamma + \theta}(1 - \frac{\mu + \gamma}{\beta}) + 1\right) \\ &= \frac{\mu + \theta}{\mu + \gamma + \theta}(\beta - (\mu + \gamma) + (\mu + \gamma + \theta)) \\ &= \frac{(\mu + \theta)(\beta + \theta)}{\mu + \gamma + \theta}, \end{aligned} \quad (2.32)$$

e la 2.31:

$$\begin{aligned} c &= \beta\gamma I_e + \beta I_e(\mu + \theta) \\ &= \beta I_e(\mu + \gamma + \theta) \\ &= \beta(1 - \frac{1}{R_0})(\mu + \theta) \\ &= \frac{\beta}{R_0}(R_0 - 1)(\mu + \theta) \\ &= (\mu + \gamma)(\mu + \theta)(R_0 - 1) \end{aligned} \quad (2.33)$$

Poiché chiaramente tutti i parametri $\beta, \gamma, \mu, \theta$ sono positivi, così come è positivo I_e , entrambi i coefficienti b e c dell'equazione sono anch'essi positivi e dunque, applicando la regola dei segni di Cartesio, si giunge alla conclusione che le parti reali delle radici di 2.29, autovalori per $\mathbf{J}_{\text{SIRS}}$, sono negative.

Ha senso esprimere gli autovalori λ_1 e λ_2 come:

$$\begin{aligned}\lambda_{1,2} &= \frac{-b \pm \sqrt{b^2 - 4ac}}{2a} \\ &= -\frac{b}{2} \pm \sqrt{\left(\frac{b}{2}\right)^2 - c}\end{aligned}\tag{2.34}$$

Il discriminante $(\frac{b}{2})^2 - c$ è realisticamente³ sempre negativo, e pertanto gli autovalori $\lambda_{1,2}$ hanno parte immaginaria $\Im(\lambda_{1,2}) \neq 0$. Biologicamente questo fatto corrisponde al presentarsi di *oscillazioni smorzate* durante l'assestamento del sistema attorno all' EE .

Tali oscillazioni avranno (pseudo-) periodo pari a

$$\begin{aligned}T_{osc} &:= \frac{2\pi}{\Im(\lambda)} \\ &= \frac{2\pi}{\sqrt{(\mu + \theta)(\mu + \gamma)(R_0 - 1) - \frac{(\mu + \theta)(\beta + \theta)^2}{2(\mu + \gamma + \theta)}}}\end{aligned}\tag{2.35}$$

, e smorzamento pari a:

$$\begin{aligned}F_{damp} &:= \Re(\lambda) \\ &= -\frac{(\mu + \theta)(\beta + \theta)}{2(\mu + \gamma + \theta)}\end{aligned}\tag{2.36}$$

Si completa così lo studio del modello SIRS:

$$\begin{cases} \text{DFE GAS, EE UNST} & \text{se } R_0 \leq 1 \\ \text{DFE UNST, EE GAS} & \text{se } R_0 > 1 \end{cases}\tag{2.37}$$

³È necessario infatti che $\mu + \gamma + \theta > 1$ e $\beta > \frac{4(\mu + \gamma)^2 + \theta(\mu + \gamma + 1)}{\mu + \gamma + \theta - 1}$. In generale queste condizioni non si verificano, a meno di contagiosità molto elevata e tempi di guarigione altrettanto brevi.

Capitolo 3

L'Epidemiologia Comportamentale delle malattie infettive

3.1 Introduzione

Come si è visto nel capitolo precedente, la diffusione o la scomparsa di un'epidemia sono fortemente interconnesse con il *basic reproduction number* R_0 .

Tale valore è a sua volta strettamente legato al comportamento degli individui che, attuando o meno certi comportamenti in situazioni emergenziali e non, possono influenzare anche notevolmente l'evoluzione dell'epidemia.

Risulta quindi interessante analizzare le specificità dei modelli epidemici alla luce anche del *comportamento* dei singoli individui durante fenomeni di *outspreading* di epidemie.

I primi studi in questo ambito, a partire dallo storico lavoro di Capasso e Serio [9] hanno dato luce a un ramo di studio che prende il nome di **epidemiologia comportamentale**.

In diverse circostanze, lo studio di modelli comportamentali ha messo in luce una maggiore attinenza ai dati e una maggiore potere predittivo, come testimoniato in [8, 10].

Storicamente sono stati distinte le due seguenti tipologie di modelli comportamentali:

1. Modelli *behaviour-explicit*, o *meccanicisti*, in cui vengono formulate ipotesi circa le modalità di interazione degli individui, ap-

plicando tecniche derivanti dalla psicologia [11] e dalla teoria dei giochi [8, 12].

2. Modelli *behaviour-implicit*, o *fenomenologici*, nelle cui equazioni non vengono direttamente postulati i meccanismi per il comportamento, ma solo il loro impatto sui vari parametri dei modelli [13]. Questa tipologia di modelli presenta, solitamente, una struttura più semplice e dunque facilmente interpretabile rispetto alla categoria di modelli precedenti, pur non mancando di generalità.

Per queste motivazioni, in questa Tesi verranno presi in considerazione modelli *behaviour-implicit*, più facilmente trattabili anche numericamente.

Un'ulteriore ipotesi sottostante ai ragionamenti in questo e nel successivo capitolo consiste nel considerare popolazioni "well-mixed", in cui non vi siano cioè cluster epidemici e, di conseguenza, la necessità di includere anche variabili spaziali nel modello né di costruire modelli di rete, più propriamente trattabili attraverso modelli ispirati alle teorie dei grafi e dei giochi [14, 15, 16].

3.2 La memoria in epidemiologia

I modelli comportamentali sono fortemente connessi al concetto di *memoria*.

Tale concetto riassume l'informazione, *anche passata*, disponibile riguardante i seguenti tre aspetti:

- La diffusione della malattia;
- Il *rischio percepito* di contrarre la malattia;
- Eventuali effetti secondari legati alle proprie decisioni, per esempio effetti collaterali contraibili con una vaccinazione.

Matematicamente, l'introduzione della memoria nei modelli comporta l'aggiunta di una nuova variabile $M(t)$, che prende il nome di **indice di informazione**. Tale variabile, il cui scopo è quantificare il livello di memoria all'interno della popolazione, permette di trattare modelli

"*information-dependent*", i cui parametri variano in funzione proprio di $M(t)$.

Nel caso in cui si tenga conto solo dell'informazione disponibile corrente, le principali formulazioni per l'informazione $M(t)$ sono:

- $M(t) = kI$, con $k > 0$, funzione lineare che quantifica la *prevalenza* corrente della malattia, cioè il numero di infettivi nell'unità di tempo t .
- $M(t) = \frac{\alpha\beta I}{\mu + \alpha\beta I}$, funzione non lineare interpretabile come misura del rischio di infezione percepito [11].
- $M(t) = \alpha\beta SI$, che sottolinea invece l'incidenza degli infettivi [17]. Questa scelta risulta più appropriata in quanto, implicitamente, mette in luce l'impatto dei mezzi di informazione attraverso il parametro α , detto *reporting rate*.

Si tratta, in quest'ultimo caso, di una funzione del tasso di incidenza, cioè di nuovi infetti: si parla dunque di *incidence-dependent memory*. Nelle precedenti due formulazioni, invece, a pesare era il numero complessivo di infetti, e pertanto si parla di modelli *prevalence-dependent*. In ogni caso, com'è ragionevole supporre, $\partial_I M(I) > 0$.

Non sempre le persone agiscono in base al tasso di informazione corrente. Questa ipotesi, infatti, non tiene conto di alcuni fattori come, per esempio, ritardi nell'accesso all'informazione. È invece più ragionevole supporre che $M(t)$ dipenda anche da valori passati delle variabili.

Per tenere dunque traccia anche dell'informazione passata, è necessario introdurre una formulazione per M più complessa:

$$M(t) = \int_{-\infty}^t K(t - \tau) f(S(\tau), I(\tau)) d\tau, \quad (3.1)$$

dove la funzione K indica il *delaying kernel* ([18]), funzione tale per cui

$$\int_0^{+\infty} K(\tau) d\tau = 1, \quad (3.2)$$

ed f una generica funzione che tiene conto della numerosità nelle classi dei suscettibili e degli infettivi.

Si noti che, scegliendo $K(\tau) = \delta(\tau)$, dove δ è nella forma di Dirac, si torna al caso dell'informazione corrente $M(t) = f(S, I)$.

L'introduzione della memoria nella sua formulazione 3.1 comporta modelli di equazioni non lineari ed integro-differenziali, particolarmente complessi da trattare.

Utilizzando una famiglia specifica di kernel, tuttavia, è possibile ricondurre la 3.1 alla forma

$$\dot{M} = a(f(S, I) - M) \quad (3.3)$$

I kernel che permettono questo risultato sono kernel Erlangiani, definiti dalla funzione di densità di probabilità

$$Erl_{n,a} = \frac{a^n}{(n-1)!} x^{n-1} e^{-ax},$$

con $x, a \in \mathbb{R}^+, n \in \mathbb{N}^+$.

Questa famiglia di modelli ha come ritardo medio $T = \frac{n}{a}$; il parametro a può in questo contesto essere interpretato quindi come il *tempo caratteristico di ritardo* della memoria, ovvero quanto tempo passa tra la ricezione dei dati e il loro effettivo impatto.

Il risultato 3.3 è valido per $Erl_{1,a}$, detto **Exponentially Fading Memory kernel**, ma è possibile generalizzare il risultato a ordini di kernel Erlangiani maggiori ([19]).

Infatti, dato un kernel $Erl_{k,a}$, applicando il *chain trick* lineare, si aggiungono al modello k nuove equazioni definite come:

$$\begin{cases} \dot{M}_j = a_1(f(s, I) - M_j) & j = 1 \\ \dot{M}_j = a_j(M_{j-1} - M_j) & j \in \{2, 3, \dots, k\} \end{cases} \quad (3.4)$$

Scelta come funzione dei dati f la semplice:

$$f(S, I) = I, \quad (3.5)$$

l'equazione 3.2 permette, all'equilibrio, di esprimere

$$M_e = \int_0^{+\infty} W(\tau) I_e d\tau = I_e \int_0^{+\infty} W(\tau) d\tau = I_e. \quad (3.6)$$

Si noti come il punto di equilibrio M_e non dipenda da a .

Questo parametro può dunque essere usato come parametro di biforcazione, ovvero un parametro per cui, cambiandone il valore, il comportamento del sistema non solo cambia ma, se tale parametro supera certe soglie passa da una tipologia di comportamento ad un'altra non equivalente.

Un secondo kernel rilevante è l'*acquisition-fading* kernel, introdotto in [20], nella forma:

$$K(t) = \frac{1}{T_b - T_a} (e^{-t/T_b} - e^{-t/T_a}) \quad (3.7)$$

Questo kernel, più realistico del precedente, modella due sotto-processi distinti e indipendenti, che avvengono secondo diverse scale temporali: il primo è rappresentato dal ritardo nell'acquisizione dell'informazione, con scala T_a , mentre il secondo consiste nel processo di affievolimento dell'informazione acquisita, con scala T_b . Solitamente, $T_b > T_a$ ([17]). Si noti che il kernel Erlangiano del secondo ordine corrisponde al 3.7 per $b \rightarrow a$ ([18, 21]).

3.3 Il modello SIR con distanziamento sociale

Un esempio di modello epidemiologico comportamentale è dato dal modello SIR con distanziamento sociale, che comunemente prende il nome di Modello di Capasso-Serio [9].

La caratteristica innovativa di questo modello è data dal parametro β espresso come funzione del tasso di memoria nella popolazione.

L'interpretazione biologica di questa formulazione è data dal fatto che, all'aumentare dell'impatto di un'epidemia sulla popolazione, questa adotterà comportamenti più cauti, riducendo così il numero medio di contatti e dunque di contagi [22, 23].

Il lavoro di Capasso e Serio si è concentrato sullo studio del modello nel caso epidemico, cioè imponendo $\mu = 0$. Studi successivi ([17]) hanno ampliato i risultati anche per $\mu > 0$.

Scelta come $\beta(M)$ una generica funzione decrescente rispetto a M , il modello si può esprimere come:

$$\begin{cases} \dot{S} = \mu(1 - S) - \beta(M)IS \\ \dot{I} = I(\beta(M)S - (\mu + \gamma)) \end{cases} \quad (3.8)$$

completato dalla solita equazione per $R = 1 - S - I$.

Poiché, per ipotesi, $\beta(0) > \beta(M)$, si può maggiorare l'equazione per le $\dot{I}$ come:

$$\dot{I} \leq I(\beta(0)(1 - I) - (\mu + \gamma)), \quad (3.9)$$

per cui, al $DFE = (1, 0, 0)$, si verifica che

$$R_0(0) = \frac{\beta(0)}{\mu + \gamma} \leq 1 \implies I(t) \xrightarrow{t \rightarrow +\infty} 0 \quad (3.10)$$

ovvero il DFE risulta GAS per $R_0 \leq 1$; viceversa, il DFE risulta instabile.

Si noti come questi risultati non dipendano dalla scelta del kernel K per M .

Inoltre, poiché

$$R_0(0) > R_0(t) \implies \frac{1}{R_0(0)} < \frac{1}{R_0(t)},$$

detto I_{eq}^{SIR} il valore della classe degli infetti all'equilibrio endemico nel modello SIR, e I_{eq}^{Cap} l'analogo per il modello 3.8, vale

$$I_{eq}^{SIR} > I_{eq}^{Cap}$$

Pur non evitando l'outspread dell'epidemia, il distanziamento sociale ha comunque un impatto sulla riduzione della sua diffusione.

Per proseguire l'analisi del modello, è utile distinguere i due casi, tenendo cioè in considerazione solo l'informazione corrente (caso *senza memoria*) oppure anche l'informazione passata. Nelle successive sezioni si considererà sempre il caso in cui l' EE esista, per $R_0(0) > 1$.

Caso senza memoria Imponendo che il distanziamento sociale venga modellato unicamente attraverso l'*incidenza* dei nuovi contagi, ovvero imponendo, implicitamente,

$$M(t) = \alpha\beta(M)S(t)I(t), \quad (3.11)$$

si può dimostrare che l'*EE* sia sempre GAS, indipendentemente dall'impatto dell'informazione corrente sull'infectious-rate $\beta(M)$ [17].

Infatti, è possibile riscrivere il sistema come:

$$\begin{cases} \dot{S} = \mu(1 - S) - \frac{M}{\alpha} \\ \dot{I} = I\left(\frac{M}{\alpha} - (\mu + \gamma)\right) \\ \dot{M} = \alpha\beta(M)SI \end{cases} \quad (3.12)$$

La matrice Jacobiana del modello è definita come:

$$\mathbf{J} = \begin{bmatrix} -\mu & 0 & -\alpha^{-1} \\ 0 & -(\mu + \gamma) & \alpha^{-1} \\ \frac{\alpha\beta I_e}{1+\alpha y} & \frac{\alpha\beta S_e}{1+\alpha y} & 0 \end{bmatrix} \quad (3.13)$$

con

$$y = -\dot{\beta}(M_e)S_eI_e > 0$$

Con semplici calcoli, si ricava a partire dalla Jacobiana 3.13 il polinomio caratteristico:

$$\left(\lambda + \mu + \frac{x}{1 + \alpha y}\right)\left(\lambda + \frac{\alpha zy}{1 + \alpha y}\right) + \frac{xz}{1 + \alpha y}, \quad (3.14)$$

con

$$\begin{aligned} x &= \beta(M_e)I_e \\ z &= \beta(M_e)S_e \end{aligned}$$

Applicando il criterio di Cartesio si evince che entrambe le radici del polinomio siano negative, e pertanto l'*EE* risulta *LAS*.

Per dimostrare la stabilità globale, invece, è necessario applicare trasformazioni continue delle variabili per poi dimostrare che la divergenza del nuovo modello sia negativa [17].

Caso con informazione passata Includendo oltre all'informazione corrente anche quella passata, il comportamento dell'equilibrio endemico del nuovo modello dipende dal delaying kernel utilizzato [17].

Adottando l'*exponentially-fading* kernel, il modello risulta avere un EE localmente stabile per ogni valore positivo associato al tempo caratteristico τ della memoria 3.3. Questo risultato comporta l'impossibilità di eradicazione della malattia, indipendentemente dalle misure di distanziamento sociale attuate dalla popolazione.

Utilizzando invece l'*acquisition-fading* kernel, che come già anticipato modella più efficacemente sia il ritardo nell'acquisizione dell'informazione sia l'evanescenza della stessa nella popolazione, e applicando poi la condizione di stabilità di Routh-Hurwitz per equazioni al quarto ordine, l' EE risulta stabile per $0 < a_1, a_2 \ll 1$ e $a_1, a_2 \gg 1$; per valori intermedi dei due pesi l' EE risulta instabile, mentre presenta cicli limite di pulsazione:

$$\omega_H^2 = \frac{q_1}{q_3} \quad (3.15)$$

per valori di (a_1, a_2) tali per cui

$$RH(a_1, a_2) = \left(\frac{q_1}{q_3}\right)^2 - \frac{q_1 q_2}{q_3} + q_0 = 0, \quad (3.16)$$

dove

$$q_3 = a_1 + a_2 + \mu + x > 0 \quad (3.17)$$

$$q_2 = a_1 a_2 (1 + \alpha y) + (a_1 + a_2)(\mu + x) + xz > 0 \quad (3.18)$$

$$q_1 = a_1 a_2 (\mu + x + (\mu + z)\alpha y) + (a_1 + a_2)xz \quad (3.19)$$

$$q_0 = a_1 a_2 z(x + \mu \alpha y) > 0 \quad (3.20)$$

Capitolo 4

Impatto del comportamento umano sulla dinamica del modello SIRS

4.1 Introduzione

Alla luce di quanto emerso nei capitoli precedenti, in questa sezione si analizzano gli effetti dell'introduzione del comportamento umano e del distanziamento sociale sulle dinamiche del modello SIRS. In una prima fase verrà discusso il modello in cui solo l'informazione corrente influenza l'infectious-rate. Nella fase successiva verranno introdotti invece modelli che sfruttano anche l'informazione passata, supponendo prima l'esistenza di un unico layer di memoria - adottando cioè l'exponentially fading memory come kernel - e poi la presenza di due layer distinti - sfruttando quindi l'acquisition fading kernel; in entrambi i casi l'informazione sarà di tipo *incidence-based*, cioè modellata attraverso l'*incidenza* della malattia.

4.2 Caso senza memoria

In questo primo caso, si intende la memoria come l'informazione corrente, slegata quindi dalla diffusione passata dell'epidemia. Si tratta ovviamente di un'approssimazione che non tiene in considerazione diversi aspetti come il ritardo nell'informazione e il fatto che questa non sia omogenea nella popolazione, oltre al fatto che le persone basino il loro comportamento anche sulla propria esperienza, legata all'informazione passata. Come si evincerà dall'analisi, tuttavia, il com-

portamento del modello non sarà molto diverso da altre versioni più complesse.

In questa sezione si è scelto un approccio per la modellazione della memoria di tipo *prevalence-based*, ovvero:

$$M(t) = I(t) \quad (4.1)$$

Riprendendo il modello SIRS 2.18 introdotto nel Capitolo 2.2.2, si può dunque esprimere il modello attraverso il seguente sistema:

$$\begin{cases} \dot{I} = I(\beta(M)S - (\mu + \gamma)) \\ \dot{R} = \gamma I - (\mu + \theta)R \\ \dot{M} = \dot{I} \end{cases} \quad (4.2)$$

dove $\beta(M)$ è una funzione decrescente. Il modello è, al solito, completato dall'equazione differenziale per $S = 1 - I - R$

Inoltre, poiché $M = I$, è possibile scrivere direttamente $\beta(I)$, e rimuovere anche l'equazione per $\dot{M}$. È pertanto conveniente riscrivere il modello come:

$$\begin{cases} \dot{I} = I(\beta(I)(1 - R - I) - (\mu + \gamma)) \\ \dot{R} = \gamma I - (\mu + \theta)R \end{cases} \quad (4.3)$$

Il modello è molto simile al 2.18, ed è pertanto logico aspettarsi un comportamento simile attorno ai punti di equilibrio che, come al solito, sono:

$$DFE = (1, 0, 0, 0) \quad (4.4)$$

$$EE = \left(\frac{1}{R_0(I_{eq})}, c \frac{\mu + \theta}{\mu + \gamma + \theta}, c \frac{\gamma}{\mu + \gamma + \theta}, I_{eq} \right), \quad (4.5)$$

dove

$$c = \left(1 - \frac{1}{R_0(I_{eq})} \right)$$

Studio DFE Perturbando il sistema attorno al DFE , si può scrivere

$$(I, R) = (0, 0) + (i, r) \quad (4.6)$$

Linearizzando, si ricava

$$\frac{di}{dt} = i(\beta(t) - (\mu + \gamma)) \quad (4.7)$$

$$\frac{dr}{dt} = \gamma i - r(\mu + \theta) \quad (4.8)$$

Supponendo i sufficientemente piccola, $\beta(i) \approx \beta(0)$, e pertanto:

$$\frac{di}{dt} \approx i(\beta(0) - (\mu + \gamma)), \quad (4.9)$$

con soluzione approssimata pari a

$$i(t) \approx i_0 e^{(\beta(0) - (\mu + \gamma))t}, \quad (4.10)$$

La 4.10 si annulla per

$$R_0(0) < 1, \quad (4.11)$$

implicando in questo caso la stabilità locale del DFE .

Maggiorando il sistema si può dimostrarne anche la convergenza globale.

Infatti, supponendo $R(t) \approx 0$ per t piccoli:

$$\begin{aligned} \dot{I} &= I(\beta(I)(1 - R - I) - (\mu + \gamma)) \\ &= I(\beta(I)(1 - R) - (\mu + \gamma)) - \beta(I)I^2 \\ &< I(\beta(I)(1 - R) - (\mu + \gamma)) \\ &\lesssim I(\beta(I) - (\mu + \gamma)) \end{aligned} \quad (4.12)$$

Posto $\dot{y} = y(\beta(y) - (\mu + \gamma))$, si ottiene quindi

$$\dot{I} < \dot{y}, \quad (4.13)$$

e poiché $Y \xrightarrow{t \rightarrow \infty} 0$ per $R_0(0) < 1$, allora necessariamente anche $I(t)$ avrà lo stesso comportamento.

Il ragionamento dimostra quindi anche la stabilità globale del DFE per $R_0 < 1$. Viceversa, poiché la 4.10 cresce esponenzialmente con il tempo, il DFE risulta instabile.

Studio EE Anche per quanto riguarda l' EE il comportamento si può supporre simile al caso senza distanziamento sociale (2.3.2).

La jacobiana del sistema è definita come

$$\mathbf{J} = \begin{bmatrix} \beta(I)S - (\mu + \gamma) - \beta(I)I & -\beta(I)I \\ \gamma & -(\mu + \theta) \end{bmatrix} \quad (4.14)$$

Valutando $\mathbf{J}$ nell' EE , ricordando che $S_e = \frac{1}{R_0(I_e)}$, si ottiene:

$$\mathbf{J} = \begin{bmatrix} -\beta(I_e)I_e & -\beta(I_e)I_e \\ \gamma & -(\mu + \theta) \end{bmatrix} \quad (4.15)$$

Per studiare la stabilità del punto si può ricorrere al **Teorema di Poincarè-Bendixson**, il quale afferma che, in un sistema due - dimensionale, la stabilità globale del modello è legata al segno negativo della **divergenza** del sistema, ovvero:

$$div(I, R)|_{EE} = \frac{\partial \dot{I}}{\partial I} + \frac{\partial \dot{R}}{\partial R} < 0 \quad \implies \quad EE \text{ LAS} \quad (4.16)$$

Applicando il teorema alla traccia della 4.15, si ottiene:

$$div(I, R) = -\beta(I_{eq})I_{eq} - (\mu + \theta) < 0 \quad (4.17)$$

e pertanto l' EE risulta essere GAS quando esiste, e cioè per $R_0(I) > 1$.

Come si può dedurre da queste analisi, il distanziamento sociale non altera il comportamento del modello. Tuttavia, essendo per ipotesi $\beta(I) < 0$, $R_0(0) > R_0(I)$, e pertanto l' I_{eq} nel modello con distanziamento sociale è minore rispetto a quello del modello senza.

4.3 1 layer di memoria

Sfruttando come *delaying kernel* il già citato Exponential Fading Memory kernel, è possibile introdurre la memoria dell'informazione passata nel modello SIRS.

Questo modello può essere dunque espresso come:

$$\begin{cases} \dot{S} = \mu(1 - S) - \beta(M)IS + \theta R \\ \dot{I} = I(\beta(M)S - (\mu + \gamma)) \\ \dot{R} = \gamma I - (\mu + \theta)R \\ \dot{M} = a(I - M) \end{cases} \quad (4.18)$$

Imponendo al solito $1 = S + I + R$, è possibile riformulare il modello come:

$$\begin{cases} \dot{I} = I(\beta(M)(1 - R - I) - (\mu + \gamma)) \\ \dot{R} = \gamma I - (\mu + \theta)R \\ \dot{M} = a(I - M) \end{cases} \quad (4.19)$$

Ricordando che all'equilibrio endemico $I_{eq} = M_{eq}$, questo modello ha come punti di equilibrio i soliti

$$DFE = (1, 0, 0) \quad (4.20)$$

$$EE = \left(\frac{1}{R_0(I_e)}, c \frac{\mu + \theta}{\mu + \gamma + \theta}, c \frac{\gamma}{\mu + \gamma + \theta} \right), \quad (4.21)$$

con

$$c = \left(1 - \frac{1}{R_0(I_e)} \right)$$

La Jacobiana $\mathbf{J}_{1\text{Lay}}$ del sistema è definita come

$$\mathbf{J}_{1\text{Lay}} = \begin{bmatrix} \beta(M)S - (\mu + \gamma) - \beta(M)I & -\beta(M)I & \dot{\beta}(M)I(1 - R - I) \\ \gamma & -(\mu + \theta) & 0 \\ a & 0 & -a \end{bmatrix} \quad (4.22)$$

Studio DFE Non sorprendentemente, maggiorando come più volte fatto l'equazione per $\dot{I}$, e imponendo $S \leq 1 - I - R$, per lievi perturbazioni in prossimità del DFE , si ricava che:

$$\begin{aligned}
\dot{I} &= I(\beta(M)S - (\mu + \gamma)) \\
&\leq I(\beta(M)(1 - I - R) - (\mu + \gamma)) \\
&\leq I(\beta(M) - (\mu + \gamma)) - \beta(M)I^2 \\
&\leq I(\beta(M) - (\mu + \gamma)) \\
&\leq I(\beta(0) - (\mu + \gamma)),
\end{aligned} \tag{4.23}$$

dove nell'ultimo passaggio si sfrutta la scelta di $\beta(M)$ decrescente. Con ragionamenti analoghi a quanto svolto per la 2.14, posto $y = I$, si risolve il sistema

$$\begin{cases} \dot{y} = y(\beta(0) - (\mu + \gamma)) \\ y(0) = I(0) \end{cases} \tag{4.24}$$

con soluzione

$$y(t) = e^{(\beta(0) - (\mu + \gamma))t} \tag{4.25}$$

Tale soluzione ha due diversi comportamenti a seconda del segno dell'argomento dell'esponenziale.

Poiché la 4.25 maggiore $I(t)$, segue che

$$R_0(0) = \frac{\beta(0)}{\mu + \gamma} < 1 \implies I(t) \xrightarrow{t \rightarrow +\infty} 0 \tag{4.26}$$

Studio EE Come visto più volte, all' EE , $\beta(M_e)S_e - (\mu + \gamma) = 0$, e dunque si può riscrivere la $\mathbf{J}_{\mathbf{1Lay}}$ come:

$$\begin{bmatrix} -\beta(I_e)I_e & -\beta(I_e)I_e & (\dot{\beta}(M_e)I_e S_e) \\ \gamma & -(\mu + \theta) & 0 \\ a & 0 & -a \end{bmatrix} \tag{4.27}$$

da cui è possibile ricavare il polinomio caratteristico:

$$\begin{aligned}
P(\lambda) &= (-a - \lambda)((-\beta(I_e)I_e - \lambda)(-(\mu + \theta) - \lambda) + \beta\gamma I_e) \\
&\quad - a\dot{\beta}(I_e)I_e S_e(-(\mu + \theta) - \lambda)
\end{aligned} \tag{4.28}$$

Con semplici passaggi si ottiene la equazione caratteristica:

$$\lambda^3 + \lambda^2(c_2 + a) + \lambda(c_0 + c_1 + ac_2) + a(c_1 + c_0) = 0, \quad (4.29)$$

dove

$$c_2 = \beta(I_e)I_e + (\mu + \theta) > 0 \quad (4.30)$$

$$c_1 = \beta(I_e)I_e(\mu + \theta + \gamma) > 0 \quad (4.31)$$

$$c_0 = -\dot{\beta}(I_e)I_e S_e > 0 \quad (4.32)$$

Per studiare il segno di tale equazione di terzo grado è utile applicare la **condizione di Routh-Hurwitz**, secondo cui:

$$\begin{cases} q_2 q_1 > q_0 & \implies & EE \text{ LAS} \\ q_2 q_1 < q_0 & \implies & EE \text{ UNST} \\ q_2 q_1 = q_0 & \implies & \text{Hopf Bifurcations} \end{cases} \quad (4.33)$$

Nel caso in questione:

$$q_2 = c_2 + a \quad (4.34)$$

$$q_1 = a(c_2 + c_0) + c_1 \quad (4.35)$$

$$q_0 = a(c_1 + (\mu + \theta)c_0) \quad (4.36)$$

Applicando quindi la condizione di Routh-Hurwitz alla 4.29, la stabilità dell'*EE* è garantita per valori di a tali per cui

$$\begin{aligned} (c_2 + a)(a(c_2 + c_0) + c_1) - a(c_1 + (\mu + \theta)c_0) &> 0 \\ (c_2 + c_0)a^2 + (c_2(c_2 + c_0) - (\mu + \theta)c_0)a + c_2 c_1 &> 0, \end{aligned} \quad (4.37)$$

Si può banalmente dimostrare come $c_2(c_2 + c_0) - (\mu + \theta)c_0 > 0$, e dunque applicando il criterio di Cartesio si deduce come entrambe le radici dell'equazione siano negative. Ne segue, considerato anche che

$c_2 + c_0 > 0$, che la 4.37 sia sempre verificata per ogni $a > 0$.
 Pertanto, si conclude che l' EE , quando è definito, sia sempre LAS .

Come già anticipato nella sezione precedente, il distanziamento sociale non ha l'impatto necessario, da solo, per evitare il diffondersi di una malattia, pur rallentandone l'outpsread.

4.4 2 layer di memoria

Un modo più realistico per modellare la memoria è attraverso l'uso dell'acquisition-fading kernel. È lecito supporre che i due layer della memoria - quello più recente che modella il ritardo nell'informazione, e quello più remoto che invece modella la persistenza dell'informazione nella memoria, una sorta di *social learning* [11] - abbiano un peso diverso, maggiore per il layer recente.

Il modello SIRS con due layer di memoria può dunque essere espresso come:

$$\begin{cases} \dot{I} = I(\beta(M_1, M_2)(1 - R - I) - (\mu + \gamma)) \\ \dot{R} = \gamma I - (\mu + \theta)R \\ \dot{M}_1 = a_1(I - M_1) \\ \dot{M}_2 = a_2(M_1 - M_2) \end{cases} \quad (4.38)$$

con, al solito, $S = 1 - R - I$.

Anche in questa circostanza, i risultati ottenuti non dipendono dalla forma specifica di $\beta(M_1, M_2)$, che però deve garantire:

$$\begin{aligned} \frac{\partial \beta(M_1, M_2)}{\partial M_1} &< 0 \\ \frac{\partial \beta(M_1, M_2)}{\partial M_2} &< 0 \end{aligned}$$

Detti per ragione di leggibilità $M = (M_1, M_2)$, $\dot{\beta}_1 = \frac{\partial \beta(M)}{\partial M_1}$, $\dot{\beta}_2 = \frac{\partial \beta(M)}{\partial M_2}$, la Jacobiana $\mathbf{J}_{2\text{Lay}}$ valutata all' EE è pari a:

$$\mathbf{J}_{2\text{Lay}} = \begin{bmatrix} -\beta(M_e)I_e & -\beta(M_e)I_e & \dot{\beta}_1(M_e)I_e S_e & \dot{\beta}_2(M_e)I_e S_e \\ \gamma & -(\mu + \theta) & 0 & 0 \\ a_1 & 0 & -a_1 & 0 \\ 0 & 0 & a_2 & -a_2 \end{bmatrix} \quad (4.39)$$

L'equazione caratteristica associata è definita come:

$$\lambda^4 + q_3\lambda^3 + q_2\lambda^2 + q_1\lambda + q_0 = 0, \quad (4.40)$$

dove:

$$q_3 = a_1 + a_2 + c_3 \quad (4.41)$$

$$q_2 = a_1a_2 + a_1(c_1 + c_3) + a_2c_3 + c_2 \quad (4.42)$$

$$q_1 = a_1a_2(c_0 + c_1 + c_3) + a_1(c_2 + c_1(\mu + \theta)) + a_2c_2 \quad (4.43)$$

$$q_0 = a_1a_2(c_2 + (c_0 + c_1)(\mu + \theta)) \quad (4.44)$$

e

$$c_3 = \beta(M_e)I_e + (\mu + \theta) \quad (4.45)$$

$$c_2 = \beta(M_e)I_e(\mu + \gamma + \theta) \quad (4.46)$$

$$c_1 = -\dot{\beta}_1(M_e)I_e S_e \quad (4.47)$$

$$c_0 = -\dot{\beta}_2(M_e)I_e S_e \quad (4.48)$$

Si noti che ciascun termine $q_j, c_k > 0$

Con l'intento di analizzare la stabilità dell' EE , supponiamo anzitutto che questo presenti, per alcuni valori (a_1, a_2) , biforcazioni di Hopf, con pulsazione ω . Necessariamente quindi la soluzione della 4.40 per λ sarà pari a $\lambda = i\omega$, con $\Re(\lambda) = 0$.

Allora si può riscrivere la 4.40 come

$$\omega^4 - q_3i\omega - q_2\omega^2 + q_1i\omega + q_0 = 0 \quad (4.49)$$

ovvero, riorganizzando i termini reali e immaginari:

$$\omega^4 - q_2\omega^2 + q_0 + i(-q_3\omega^3 + q_1\omega) = 0 \quad (4.50)$$

Affinché l'equazione 4.50 sia rispettata, è necessario che sia la parte reale che quella immaginaria si annullino.

Imponendo $\Im m = 0$, si ricava:

$$\omega^2 = \frac{q_1}{q_3} \quad (4.51)$$

ed infine, imponendo $\Re e = 0$, ed inserendo nell'equazione la 4.51 si ottiene:

$$\left(\frac{q_1}{q_3}\right)^2 - q_2 \frac{q_1}{q_3} + q_0 = 0, \quad (4.52)$$

analoga nella forma a quanto ottenuto nella 3.16.

Per il criterio di Routh-Hurwitz, quando l'equazione è verificata, attorno all'equilibrio endemico si manifestano biforcazioni di Hopf.

Quando invece l'espressione ha segno negativo, le radici della 4.52 sono anch'esse negative, e pertanto l' EE sarà LAS , mentre viceversa, quando l'espressione ha segno positivo, l' EE è instabile [24].

Lo studio del segno della 4.52, tuttavia, risulta di difficile soluzione analitica.

Ricorrendo ad approssimazioni, supponendo $a_1, a_2 \gg 1$, la 4.52 risulta sempre positiva per $c_0 + c_1 + c_3 > 1$, e pertanto l' EE risulterebbe stabile.

Tale condizione si verificherebbe per $-\dot{\beta}_1 - \dot{\beta}_2 \gg 1$, ovvero per alta instabilità nel comportamento della popolazione: per valori alti di infettività effettivamente il distanziamento sociale è fortemente applicato, e questo riduce l'infectious rate β e di conseguenza il numero di infetti, ma appena questo si abbassa anche lievemente l'attenzione della popolazione cala e i contagi riprendono. È sensato quindi aspettarsi un comportamento poco oscillatorio, in cui si raggiunge velocemente l'equilibrio endemico.

Analogamente, per $a_1, a_2 \ll 1$, cioè per bassa reattività della popolazione all'outspread della malattia, l' EE continua a rimanere stabile. Infine, per combinazioni di valori intermedi dei pesi dell'informazione, è possibile che si verifichino biforcazioni di Hopf e situazioni di instabilità locale dell' EE .

Nessuna delle diverse simulazioni effettuate, con alcuni esempi riportati nella Figura 4.4.1, tuttavia presenta tali comportamenti, e pertanto

si è portati a supporre che l' EE sia globalmente stabile ove definito.




Figura 4.4.1: La stabilità del modello SIRS è confermata per diversi valori di a_1 e a_2 . In questo pannello, è presentato il piano di fase per le classi I, R di 9 modelli. Altri parametri come sopra.

Dalla Fig. 4.4.2, invece, è possibile evincere come la modellazione della memoria attraverso 2 layer ha un effetto positivo, riducendo notevolmente il numero totale di infetti. L'uso dell'informazione permette di “tagliare” i picchi di nuove infezioni, praticamente eliminando le oscillazioni e favorendo in questo modo il raggiungimento veloce dell'equilibrio endemico.




Figura 4.4.2: Dinamica degli infettivi per 4 diversi modelli: SIRS senza distanziamento sociale (in blu), SIRS senza informazione passata (rosso), SIRS con 1 layer di memoria (verde), SIRS con 2 layer di memoria (in verde). Da notare come, all'equilibrio, i valori siano pressoché uguali. Differisce invece l'incidenza cumulativa totale, ovvero il numero totale di infetti durante il periodo considerato. Parametri usati: $\gamma = \frac{1}{7 \text{ days}}$, $R_0 = 2$, $\mu = \frac{1}{80 \text{ years}}$, $\theta = \frac{1}{30 \text{ days}}$.

4.5 Memoria di tipo *incidence-based*

Una strategia diversa per modellare la memoria consiste nel supporre che le persone agiscano non tanto in conseguenza al numero totale di infetti (*prevalence-dependent*), ma in base alla crescita o al rallentamento della diffusione della malattia: a contare sono quindi i "nuovi infetti". Questo approccio prende il nome di memoria *incidence-based*.

Supponendo la modellazione attraverso un unico layer di memoria, il sistema è così formulato:

$$\begin{cases} \dot{S} = \mu(1 - S) - \beta(M)SI + \theta(1 - S - I) \\ \dot{I} = I(\beta(M)S - (\mu + \gamma)) \\ \dot{M} = a(k\beta(M)SI - M) \end{cases}, \quad (4.53)$$

completato da $R = 1 - S - I$, e con $k > 0$ indicante il *peso* della memoria.

All'equilibrio endemico la Jacobiana $\mathbf{J}_{\text{inc}}$ del modello è pari a:

$$\mathbf{J}_{\text{inc}} = \begin{bmatrix} -(\mu + \theta + h) & -(k + \theta) & b \\ h & 0 & -b \\ ah & ak & -a(b + 1) \end{bmatrix} \quad (4.54)$$

dove $h = \beta(M)I_e$, $k = \beta(M)S_e$ e $b = -c\dot{\beta}(M)S_eI_e > 0$.

Con semplici calcoli si giunge alla seguente formulazione del polinomio caratteristico:

$$P(\lambda) = \lambda^3 + q_2\lambda^2 + q_1\lambda + q_0, \quad (4.55)$$

dove

$$q_2 = a(b + 1) + h + \mu + \theta \quad (4.56)$$

$$q_1 = a(b(\mu + \theta + k) + h + \mu + \theta) + h(k + \theta) \quad (4.57)$$

$$q_0 = a(bk(\mu + \theta) + h(k + \theta)) \quad (4.58)$$

Applicando la condizione di Routh-Hurwitz al terzo ordine, l' EE è *LAS* se

$$q_2q_1 - q_0 > 0, \quad (4.59)$$

ovvero, posto $x = h + \mu + \theta$, $y = k + \mu + \theta$ e $z = h(k + \theta)$:

$$\begin{aligned} 0 &< q_2q_1 - q_0 \\ &< (a(b + 1) + x)(a(x + by) + z) - a(bk(\mu + \theta) + z) \\ &< a^2(b + 1)(x + by) + a(x^2 + b(xy + z - k(\mu + \theta))) + xz \\ &< a^2(b + 1)(x + by) + a(x^2 + b(hk + z + x(\mu + \theta))) + xz, \end{aligned} \quad (4.60)$$

condizione sempre verificata in quanto:

$$h_2 = (b + 1)(x + by) > 0 \quad (4.61)$$

$$h_1 = (x^2 + b(hk + z + x(\mu + \theta))) > 0 \quad (4.62)$$

$$h_0 = xz > 0 \quad (4.63)$$

Pertanto, con questo tipo di modellazione basato sull'incidenza, l' EE risulta sempre stabile, indipendentemente dal tempo caratteristico della memoria e dal rischio percepito della malattia.

Applicando invece un acquisition kernel il modello diventa:

$$\begin{cases} \dot{S} = \mu(1 - S) - \beta(M_1, M_2)SI + \theta(1 - S - I) \\ \dot{I} = I(\beta(M_1, M_2)S - (\mu + \gamma)) \\ \dot{M}_1 = a_1(c\beta(M_1, M_2)SI - M_1) \\ \dot{M}_2 = a_2(M_1 - M_2) \end{cases} \quad (4.64)$$

completato sempre da $R = 1 - S - I$. Per semplicità si è posto poi $c = 1$.

Il polinomio caratteristico associato è nella solita forma:

$$P(\lambda) = \lambda^4 + q_3\lambda^3 + q_2\lambda^2 + q_1\lambda + q_0, \quad (4.65)$$

dove in questo caso:

$$b_1 = -\frac{\partial\beta(M_1, M_2)}{\partial M_1}S_eI_e \quad (4.66)$$

$$b_2 = -\frac{\partial\beta(M_1, M_2)}{\partial M_2}S_eI_e \quad (4.67)$$

$$w = k(\mu + \theta) \quad (4.68)$$

$$q_3 = a_1(b_1 + 1) + a_2 + x \quad (4.69)$$

$$q_2 = a_1a_2(b_1 + b_2 + 1) + a_1(b_1y + x) + a_2x + z \quad (4.70)$$

$$q_1 = a_1a_2(y(b_1 + b_2) + x) + a_1(b_1w + z) + a_2z \quad (4.71)$$

$$q_0 = a_1a_2(w(b_1 + b_2) + z) \quad (4.72)$$

L'equazione potrebbe essere risolta applicando il criterio di Cardano. Tuttavia, il procedimento risulta particolarmente laborioso visto il numero di parametri in gioco, e pertanto si ricorre a simulazioni numeriche.

In questa circostanza, a differenza del caso con memoria di tipo prevalence-based, si può incorrere in situazioni di instabilità dell'equilibrio endemico per valori intermedi di a_1 e a_2 .

Invece, per valori $(a_1, a_2) \approx 0$ l'EE risulta dalle simulazioni sempre stabile, così come per valori di a_1, a_2 sufficientemente grandi, con tempi caratteristici dell'ordine di qualche giorno, con la conseguente presenza anche di cicli limite per determinati valori dei due tempi caratteristici.

4.6 Caso senza dinamica vitale

In molti casi l'outbreak iniziale della malattia è talmente rapido e intenso da poter supporre $\mu \approx 0$.

Solo dopo alcune unità di tempo le dinamiche vitali assumono una certa rilevanza ed è quindi necessario integrarle affinché il modello abbia una rilevanza.

Analizzando il modello SIRS nelle fasi iniziali di diffusione dell'epidemia, si nota come, per periodi di immunità molto brevi, o equivalentemente per valori grandi di θ , il modello si assesti molto rapidamente attorno ad un certo valore $\tilde{E} = (\tilde{S}, \tilde{I}, \tilde{R})$ molto prossimo all'equilibrio endemico, a cui il modello tende poi lentamente introducendo il parametro vitale μ .

Il valore $\tilde{E}$ può quindi essere considerato come una sorta di "equilibrio transitorio", o "pseudo-equilibrio", ed è ricavabile analiticamente come equilibrio endemico del modello SIRS senza dinamica vitale.

Considerato il rapporto tra i due valori di equilibrio per la classe degli infetti $\tilde{I}$ e I_e (SIRS con dinamica vitale), vale:

$$\frac{I_e}{\tilde{I}} = \frac{\left(1 - \frac{1}{R_0}\right) \frac{\mu + \theta}{\mu + \gamma + \theta}}{\left(1 - \frac{\gamma}{\beta}\right) \frac{\theta}{\gamma + \theta}} \quad (4.73)$$

$$= \frac{\beta - \mu - \gamma}{\beta - \gamma} \frac{(\mu + \theta)(\gamma + \theta)}{\theta(\mu + \gamma + \theta)} \quad (4.74)$$

$$= \frac{\beta - \mu - \gamma}{\beta - \gamma} \left(1 + \frac{\mu\gamma}{\theta^2 + \theta(\mu + \gamma)}\right), \quad (4.75)$$

molto prossimo a 1 per $\theta \gg \mu$.

Introducendo invece la memoria, l'equilibrio si sposta proporzionalmente all'intensità del distanziamento sociale, e l'approssimazione attraverso l'equilibrio transitorio non risulta più realistico.

Come si nota dalla Fig. 4.6.3, infatti, le oscillazioni iniziali assestano il modello su valori minori nel numero di infetti.

Le forti oscillazioni per $t > 5000$ sono dovute a errori numerici, ma la tendenza attorno all' $\tilde{I}$ è comunque evidente.




Figura 4.6.3: $I(t)$ nei vari modelli senza dinamica vitale (linea rossa tratteggiata), con dinamica vitale e senza memoria (in blu), con dinamica vitale e memoria (in verde). A sinistra, $t = [0, 1000]$. A destra, $t = [1000, 50000]$. Parametri: $\gamma = \frac{1}{7}$, $R_0 = 5$, $\mu = \frac{1}{80 \text{ years}}$, $\theta = \frac{1}{30 \text{ days}} \gg \mu$. t in giorni.

Capitolo 5

Simulazioni dinamiche e biforcazioni numeriche

5.1 Introduzione

In questa sezione verranno presentati i principali risultati delle simulazioni riguardanti le varianti del modello SIRS presentate nei capitoli precedenti.

In un primo momento l'obiettivo delle simulazioni è dimostrare l'importanza dell'applicazione di misure di distanziamento sociale al fine di limitare il numero di individui contagiati.

In un secondo momento, invece, l'attenzione sarà posta sugli effetti delle diverse strategie di modellizzazione della memoria.

Ove non altrimenti specificato, verranno fissati i parametri seguenti:

$$\gamma = \frac{1}{7 \text{ days}}$$
$$\mu = \frac{1}{80 \text{ years}}$$

Il valore per γ corrisponde ad un tempo medio di guarigione $T_\gamma \approx 7$ giorni, che è una buona media per diverse malattie comuni come l'influenza.

Il valore per μ , invece, è legato all'aspettativa di vita media di un individuo, pari a circa $T_\mu \approx 80$ anni in una moderna società occidentale.

5.2 Impatto del distanziamento sociale

Come già anticipato nello studio analitico del modello SIRS con $\beta(M)$, l'applicazione del distanziamento sociale non è in grado, da sola, di estinguere la malattia, indipendentemente dalla forma analitica associata a $\beta(M)$, dal peso e dal tempo caratteristico associato ai diversi layer della memoria.

Tuttavia, come già brevemente accennato nella Fig. 4.4.2, non si può escludere una sua effettiva importanza.

Una misura interessante per quantificare la bontà del modello è l'*incidenza cumulativa*, ovvero il numero totale di nuovi infetti per ciascun giorno. Minore è questo valore, ovviamente, migliore sarà la situazione nella popolazione.

Ricordando che il tasso di contagio medio J per unità di tempo è

$$J = \beta(M)SI, \quad (5.1)$$

è sufficiente integrare nell'intervallo di tempo considerato $[a, b]$ per ottenere il numero totale di nuove infezioni $\tilde{J}$:

$$\tilde{J} = \int_a^b J(t)dt = \int_a^b \beta(M(t))S(t)I(t)dt \quad (5.2)$$

Fissati i classici parametri γ, θ, μ e R_0 , i parametri che permettono di regolare l'intensità dell'informazione acquisita, e dunque di diminuire l'incidenza cumulativa, sono i tempi caratteristici della memoria a_1 e a_2 , e soprattutto il peso della memoria stessa, k .

Questo parametro contribuisce quando si associa a $\beta(M)$ una forma specifica. Le più comuni sono:

- $\beta(M) = (\beta(0) - kM)_+$, ovvero una forma lineare. Questa scelta è critica perché, per valori di $M > \frac{\beta(0)}{k}$, il tasso di infettività è nullo, e questo è poco realistico.
- $\beta(M) = \beta(0)e^{-kM}$. Anche questa forma presenta criticità perché per k sufficientemente grandi decade rapidamente allo 0.
- $\beta(M) = \frac{\beta(0)}{1+kM}$, che ha un decadimento meno rapido e quindi più realistico.




Figura 5.2.1: Diversi modelli SIRS per diversi parametri. In blu, SIRS base; in rosso, SIRS con informazione corrente; in verde SIRS con un layer di memoria; in arancio SIRS con due layer di memoria.

Parametri: Alto a sx: $R_0 = 1.05, \theta = \frac{1}{3650 \text{ days}}$. Alto a dx: $R_0 = 2, \theta = \frac{1}{365 \text{ days}}$. Basso a sx: $R_0 = 5, \theta = \frac{1}{180 \text{ days}}$. Basso a dx: $R_0 = 18, \theta = \frac{1}{30 \text{ days}}$. Fissati: $a_1 = \frac{1}{15 \text{ days}}, a_2 = \frac{1}{90 \text{ days}}, k = 50$. Tempo di studio considerato: 10 anni.

Per le ragioni appena espresse, in questo capitolo la scelta ricade sulla forma iperbolica.

Poter quantificare il valore di k più adatto per i vari modelli richiede qualche approssimazione.

Per esempio, supponendo di voler scegliere k affinché:

$$\beta(M_e) = \frac{\beta(0)}{100},$$

e chiedendo un $I_e < 0.05$, si ricava tramite sostituzioni $k > 1980$. Accontentandosi invece di $\beta(M_e) = \beta(0)/5$, e $I_e < 0.1$, allora $k > 40$.

Non potendo associare a k un'unità di misura, né tantomeno potendone dare un significato meno generico, la scelta di k risulta quindi piuttosto arbitraria.

Nelle prossime simulazioni, si è scelto $k = 50$.




Figura 5.2.2: Diversi modelli SIRS avendo fissato R_0 sulle righe e θ sulle colonne. In blu il modello SIRS senza memoria, in rosso il modello con solo informazione corrente, in verde il modello con un unico layer ed infine in arancio il modello con entrambi i layer di memoria.

Come si evince dalla Fig. 5.2.1, l'introduzione della memoria permette di ridurre notevolmente i picchi delle oscillazioni, favorendo così il raggiungimento dell'equilibrio endemico. Questo processo è tanto più veloce quanto maggiore è R_0 e minore il tempo caratteristico dell'immunità $T_\theta = \theta^{-1}$.

Ne segue una riduzione notevole dell'incidenza totale che, nel caso classico di una comune influenza, passa dal valore adimensionale di 50.1 del caso senza informazione, a 24.2 del caso migliore con memoria composta da due layer: si tratta di una riduzione di più del 50% (in alto a dx nella Fig. 5.2.1). Tale riduzione aumenta in proporzione all'aumentare dell'infettività della malattia e alla riduzione dell'immunità. Nel caso più estremo considerato, in basso a destra nella Fig. 5.2.1, in cui i modelli SIRS sono stati simulati con parametri tipici del raffreddore, la riduzione supera il 71%.

Risulta interessante capire se a pesare maggiormente circa la contagiosità della malattia sia il basic reproduction number R_0 o invece il periodo di immunità T_θ : dalla Fig. 5.2.2, si nota come il comporta-

mento dei diversi layer differisca molto di più al variare di θ per R_0 fissato, mentre viceversa il cambiamento è molto minore.

È inoltre interessante studiare il comportamento dei modelli al variare, invece, dei tempi caratteristici e dei pesi associati alla memoria. Nelle simulazioni mostrate in Fig. 5.2.3, si considerano fissati $R_0 = 2$ e $\theta = \frac{1}{1 \text{ year}}$.




Figura 5.2.3: Andamento della memoria in diversi modelli SIRS con 1 layer (pannello a sinistra, solo M1) e 2 layer (pannello a destra, M1+M2) di memoria, per diversi valori di a_1 e a_2 . Rosa: $a_1 = 1/15\text{days}$, $a_2 = 1/30\text{days}$; Verde: $a_1 = 1/30\text{days}$, $a_2 = 1/90\text{days}$; Azzurro: $a_1 = 1/90\text{days}$, $a_2 = 1/180\text{days}$; Ocra: $a_1 = 1/180\text{days}$, $a_2 = 1/365\text{days}$. $k = 50$. Altri parametri come riportati nel testo.

Dalla Fig. 5.2.3 si nota come, all'aumentare del tempo caratteristico della memoria $\tau = a_1^{-1}$, in entrambe le varianti del modello SIRS aumentino anche le oscillazioni delle variabili. Questo risultato è alquanto controintuitivo: è naturale aspettarsi infatti che, tenendo in considerazione una maggiore porzione di “memoria”, il sistema risenta in maniera minore degli effetti delle oscillazioni nel numero di infettivi, e quindi abbia un andamento più “lineare”.

In realtà, ricordando che, nel caso con un solo layer di memoria, $\frac{\partial M}{\partial t} = a_1(I - M)$, per a_1 piccoli la variabile $\frac{\partial M}{\partial t}$ si muove molto len-




Figura 5.2.4: Due modelli SIRS con distanziamento sociale basato su 2 layer di memoria: a sinistra, $R_0 = 5, \theta = \frac{1}{180 \text{ days}}$, a destra $R_0 = 1.5, \theta = \frac{1}{30 \text{ days}}$. In ciascun pannello, è mostrato l'andamento della memoria per diversi pesi di a_1 e a_2 , i cui valori sono i medesimi della Fig. 5.2.3

tamente, facendo prevalere il ritardo di fase tra I ed M , e dunque le oscillazioni rispetto all'equilibrio.

La differenza nel comportamento tra i diversi tempi caratteristici aumenta al diminuire di R_0 e θ : maggiori sono le oscillazioni che il modello presenta per sua natura, maggiore è la sensibilità della memoria per τ “grandi” (cfr. Fig. 5.2.4 per due esempi). Viceversa, per valori maggiori di R_0 e θ , più uniformi sono le oscillazioni: la memoria ha un impatto piuttosto simile a prescindere dai diversi τ .

Per queste ragioni, all'aumentare dei τ , aumenta, seppur lievemente, anche l'incidenza cumulativa, con i valori riportati nelle varie figure, sempre calcolati su un periodo complessivo di 100 anni.

Un ultimo elemento interessante da analizzare è legato al peso del parametro k . Naturalmente, ci si aspetta che, all'aumentare di k , diminuisca l'infectious rate $\beta(M)$ e dunque diminuisca l'incidenza cumulativa.

In effetti non solo questa ma anche le ampiezze delle oscillazioni dimi-

nuiscono; contemporaneamente, inoltre, aumenta la velocità del modello che raggiunge l'equilibrio endemico in sempre meno tempo (Fig. 5.2.5).




Figura 5.2.5: Andamento nel numero di infettivi nel modello SIRS con due layer di memoria, per diversi valori di k . Blu: $k = 1$; Arancio: $k = 10$; Verde: $k = 50$; Rosso: $k = 100$. Fissi i parametri $R_0 = 2$, $\theta = \frac{1}{365 \text{ days}}$, $a_1 = \frac{1}{15 \text{ days}}$, $a_2 = \frac{1}{90 \text{ days}}$.

In ultima analisi, dunque, il distanziamento sociale è una misura che, come più volte evidenziato, permette l'arginamento della malattia in maniera fortemente dipendente dall'intensità della misura - il *peso* k associato alla memoria.

5.3 Confronto tra informazione prevalence-based e informazione incidence-based

Un secondo aspetto meritevole di attenzione riguarda le differenze dei modelli con informazione basata sulla prevalenza e quelli con informazione legata all'incidenza, in cui a pesare sono i “nuovi” infetti. Buona parte dei ragionamenti fatti nello scorso capitolo rimangono veri anche per memorie incidence-based.




Figura 5.3.6: Confronto della numerosità della classe degli infetti per diversi modelli SIRS. Nei diversi pannelli, diverse coppie di valori per R_0 e θ . In rosa, il modello SIRS con 1 layer di memoria prevalence-based, in grigio il modello SIRS con 2 di memoria prevalence-based, in azzurro e in arancio il modello SIRS con 1 e 2 layer di memoria incidence-based.

Tuttavia, confrontando diverse varianti del modello SIRS - con memoria a 1 o 2 layer, e di tipo prevalence-based o incidence-based - emerge come il comportamento dei modelli con memoria basata sull'incidenza sia alquanto imprevedibile (Fig. 5.3.6): mentre il modello con due layer di memoria abbattere notevolmente i picchi di infezione, con un'incidenza cumulativa totale inferiore anche a più dell'80%, il modello con un unico layer di memoria è, nei 4 casi mostrati in figura, visibilmente il peggiore.

Probabilmente questo modello risulta essere troppo sensibile all'andamento della memoria. La differenza di comportamento, inoltre, aumenta all'aumentare di k , come illustrato in Fig. 5.3.8, mentre non risulta essere dipendente dai tempi caratteristici delle memorie, come si può evincere dalla Fig. 5.3.8.

Stiamo investigando gli esiti di tali simulazioni per comprenderne il significato biologico.




Figura 5.3.7: Confronto della numerosità della classe degli infetti per diversi modelli SIRS. Nei diversi pannelli, diverse coppie di valori per i tempi caratteristici della memoria a_1^{-1} e a_2^{-1} .




Figura 5.3.8: Confronto della numerosità della classe degli infetti per diversi modelli SIRS. Nei diversi pannelli, diversi valori per il peso della memoria k .

Capitolo 6

Esplorazione dei metodi di ricostruzione neurale applicati al modello SIRS

6.1 Il problema della ricostruzione dei sistemi dinamici

Le simulazioni fino a qui mostrate si fondano sulla conoscenza completa dei parametri caratterizzanti il modello presentato $(\beta, \theta, \gamma, \mu)$, del modello di contagio (via la legge di azione di massa [3]) e dell'impatto di informazione e memoria. La realtà è però ben più complessa: dovendo trattare, per esempio, malattie infettive nuove, non sempre è possibile risalire a valori accurati dei tassi di infettività e di immunità specifici per la data malattia; si deve invece ricorrere ad approssimazioni per stime di tali valori, compromettendo l'affidabilità dei modelli ricavati che, come si è evinto anche dai precedenti capitoli, sono spesso estremamente sensibili.

Nell'ultima decina di anni, tuttavia, nuovi articoli scientifici hanno introdotto sia tecniche e architetture di *deep learning* per poter risolvere numericamente equazioni differenziali (sfruttando la capacità della reti neurali di essere approssimatori universali) sia per ricostruire le dinamiche dei sistemi a partire da osservazioni sperimentali (o da dati sintetici realistici).

In questo capitolo verranno applicate al modello SIRS tre diverse architetture: le Residual Networks (ResNet), le Neural Ordinary Differential Equations (NeuralODEs) e le Universal Differential Equations

(UDEs).

Si noti come questo capitolo non ha tanto la pretesa di fornire un’analisi esaustiva dell’applicazione di tecniche di deep learning in ambito epidemiologico, quanto la semplice intenzione di presentare una prima introduzione di tipo esplorativo a questo interessante argomento.

6.2 I principali metodi di ricostruzione dei sistemi dinamici

6.2.1 Residual Networks

Il framework del residual learning è stato presentato da K. He e collaboratori come strumento applicabile inizialmente in ambito di *computer vision* [25].

L’idea da cui trae spunto il concetto di residuo è la seguente: se la rete neurale applica all’input x una trasformazione $\mathcal{F}(x)$ il cui risultato $\mathcal{H}(x)$ è molto simile all’input (per esempio, se si vuole fare iper-risoluzione di un’immagine, il risultato sarà in gran parte simile all’originale a meno di alcuni pixel), allora anziché imparare la trasformazione $\mathcal{F}$ conviene invece imparare il **residuo**, definito come $\mathcal{H}(x) - x$. Nella pratica, questo approccio coincide con la cosiddetta *skip connection*, ovvero la somma dell’input al residuo stimato dalla rete neurale.

Questo approccio permette di risolvere il problema del cosiddetto *vanishing gradient* [26] [27] : reti neurali particolarmente profonde, infatti, tendono a causa di errori numerici ad avere errori di training maggiori rispetto a controparti più *shallow*, limitando quindi il potere di generalizzazione delle reti neurali profonde. L’introduzione del residuo permette di superare queste limitazioni garantendo risultati eccellenti, per esempio nei classici benchmark CIFAR-10 e ImageNet [25].

L’applicazione della ResNet ai sistemi dinamici è piuttosto diretta: immaginando di applicare numerose skip connection alla rete, queste architetture possono infatti essere interpretate come “discretizzazioni euleriane di trasformazioni continue” [28] [29]:

$$X_{t+1} - X_t = \mathcal{F}(X_t), \quad (6.1)$$

dove in questo caso t è la profondità del layer considerato.

L'uso delle ResNet permette quindi di ricostruire la dinamica dei modelli nel (raro) caso in cui il Δt di sampling dei dati sia costante. Il vantaggio principale di questa architettura riguarda la possibilità di addestrare la rete neurale attraverso la comune backpropagation, a differenza delle successive architetture.

6.2.2 Neural Ordinary Differential Equations

Cosa succederebbe se, a partire da una ResNet, venissero aggiunti *infiniti* layer ad *infinitesima* “distanza” δt uno dall'altro?

Questa è stata la domanda sottostante al lavoro di Chen et al. [28], consistente nella parametrizzazione continua delle *hidden units* della rete neurale attraverso un'equazione differenziale ordinaria (ODE):

$$\frac{d}{dt}x(t) = \mathcal{F}(x(t), t, \theta) \quad (6.2)$$

L'uso delle Neural ODE per la definizione di sistemi dinamici ha numerosi benefici, tra cui efficienza in memoria, la computazione adattiva attraverso solver di ODE dinamici e la possibilità di analisi di serie temporali continue.

Tuttavia, poiché la backpropagation è pensata per reti neurali a profondità discrete, l'uso delle Neural ODE necessita di un nuovo framework per poter calcolare i gradienti rispetto ai pesi, detto metodo di *adjoint sensitivity* [30].

Questo metodo consiste nell'introduzione dell'**adjoint state**, definito come $a(t) = \frac{\partial \mathcal{L}}{\partial x(t)}$; l'adjoint ha poi una sua dinamica, a sua volta definita come:

$$\frac{\partial}{\partial t}a(t) = -a(t)^T \frac{\partial}{\partial x} \mathcal{F}(x(t), t, \theta) \quad (6.3)$$

A partire dall'adjoint, si può scrivere il gradiente della loss $\mathcal{L}$ rispetto ai pesi θ come:

$$\frac{d}{d\theta} \mathcal{L} = - \int_{t_1}^{t_0} a(t)^T \frac{\partial}{\partial \theta} \mathcal{F}(x(t), t, \theta) dt \quad (6.4)$$

Attraverso l'*automatic differentiation* si possono velocemente valutare $a(t)^T \frac{\partial}{\partial x} \mathcal{F}$ e $a(t)^T \frac{\partial}{\partial \theta} \mathcal{F}$.

Inoltre, applicando l'algoritmo detto di *reverse-mode differentiation*,

si può risolvere il sistema dato dallo stato originale $x(t_0)$, da $\frac{\partial}{\partial x(t_0)}\mathcal{L}$ e dal consueto gradiente $\frac{\partial}{\partial \theta}\mathcal{L}$ attraverso un'unica chiamata a un risolutore di ODE.

6.2.3 Universal Differential Equations

Le Neural ODEs possono essere interpretate come un caso particolare di Universal Differential Equations [31]. Questa architettura, infatti, definisce un'equazione differenziale come [31]:

$$\frac{d}{dt}x(t) = g(x(t), t, \mathcal{F}(x, t)), \quad (6.5)$$

dove $\mathcal{F}$ rappresenta la funzione approssimata attraverso una rete neurale, mentre g è una qualsiasi funzione definita. [31]

Questo approccio permette di includere, in g , informazioni note dalla fisica o biologia etc.... del problema da modellare con equazioni differenziali; nell'ambito dei sistemi dinamici, permette di formulare un *embedding* di quanto conosciuto del modello, lasciando alla rete neurale il compito di imparare le parti del sistema non note, e garantendo una maggiore interpretabilità dei risultati ottenuti.

Inoltre, questo approccio permette di risolvere non solo ODE ma anche equazioni differenziali alle derivate parziali, equazioni differenziali con ritardo o stocastiche.

Come per le Neural ODE, anche le UDE possono essere risolte attraverso metodi di adjoint.

6.3 Ricostruzione del modello SIRS

L'obiettivo principale di questa sezione è la ricostruzione del modello a partire da dati estratti dal modello stesso. In un primo momento verranno analizzate le specificità delle architetture applicate a dati non sporcati, per poi analizzare invece l'applicazione a dati sporcati con rumore gaussiano.

Per poter ricostruire in maniera efficace il modello SIRS è stato sfruttato l'ambiente fornito dal linguaggio di programmazione Julia, e dalle sue librerie *DiffEqFlux* e *DifferentialEquations*.

Per poter ricostruire le ODE sono stati scelti i seguenti metodi:

- **Tsitouras 5/4** come metodo di integrazione in avanti. Si tratta di un integratore esplicito a passo variabile, efficiente per ODE ben condizionate. fa parte della famiglia dei metodi di Runge-Kutta a 5 stadi. È il metodo predefinito fornito dalla libreria *DiffEqFlux*
- **Interpolating Adjoint** come tecnica di adjoint sensitivity per il calcolo del gradiente. Si tratta di un metodo che, durante il forward pass, salva un'interpolazione continua della soluzione della ODE, sfruttata poi nel backward pass per integrare più velocemente la ODE dell'adjoint.
- **Reverse-mode Differentiation** per computare il vettore jacobiano-prodotto legato alla risoluzione dell'equazione 6.4.

Per poter fornire risultati più generali, sono stati studiati due modelli SIRS non comportamentali con diversi parametri; in entrambi i casi sono fissati $\gamma = \frac{1}{7 \text{ days}}$ e $\mu = \frac{1}{80 \text{ years}}$ e $\theta = \frac{1}{365 \text{ days}}$, mentre variano R_0 , pari a 2 nel primo caso e a 10 nel secondo caso considerato, e il tempo t di osservazione, pari a 2000 giorni nel primo caso e a 500 nel secondo. Tali valori non sono casuali, ma riflettono due diverse possibili dinamiche del modello SIRS, con ampie oscillazioni nel caso con $R_0 = 2$ e con un raggiungimento rapido del EE nel caso in cui $R_0 = 10$.




Figura 6.3.1: La classe degli infetti nei due diversi modelli SIRS da ricostruire. Nel pannello a sinistra, $R_0 = 2$, in quello a destra, $R_0 = 10$




Figura 6.3.2: La ricostruzione della classe di infetti operata dalle diverse architetture. Nel pannello a sinistra, il modello SIRS con $R_0 = 2$, nel pannello a destra il modello SIRS con $R_0 = 10$. In blu, i dati reali; in rosso la ricostruzione attraverso ResNet; in verde la ricostruzione tramite NeuralODE e in arancio la ricostruzione tramite UDE. Parametri come anticipati nel testo.

Le architetture implementate, indipendentemente dal tipo di dato (pulito o con rumore) che devono trattare, prevedono l'utilizzo di layer densi, in numero variabile e con diverse funzioni di attivazione, come da tabella:

Architettura	Numero di Layer	Dimensioni dei Layer	Funzione di Attivazione
ResNet	3	(3, 64), (64, 64), (64, 3)	ReLU
NeuralODE	3	(3, 16), (16, 16), (16, 3)	Tanh
UDEs	2	(3, 32), (32, 1)	Tanh

Tabella 6.3.1: Struttura delle architetture implementate

Architettura	$R_0 = 2$	$R_0 = 10$
ResNet	0.000697	0.000104
Neural ODE	0.005466	0.121223
UDE	0.001383	0.000955

Tabella 6.3.2: Valori di $loss$ per i tre modelli nel caso SIRS con $R_0 = 2$ e $R_0 = 10$, a partire da dati puliti

Dati “puliti” I risultati ottenuti sono stati piuttosto vari, come confermato dalla Figura 6.3.2 e dalla Tabella 6.3.2, riportanti rispettivamente le dinamiche ricostruite e le loss delle varie architetture.

Le ResNet, dopo 10.000 epoche di addestramento, riescono a seguire piuttosto fedelmente le dinamiche dei due modelli, con un *Mean Squared Error* (MSE) in entrambi i casi dell'ordine di 10^{-4} .

Tuttavia, mentre nel caso di $R_0 = 10$, la ResNet ricostruisce perfettamente il modello, nel caso con $R_0 = 2$ dopo i primi 300 giorni l'architettura tende ad anticipare e ad amplificare le oscillazioni, per poi assestarsi attorno all' EE .

Il risultato delle ResNet risulta comunque sorprendente se si considera il fatto che il tempo totale di addestramento, svolto su CPU, non ha superato i due minuti.

Pur trattandosi di un'architettura semplice, dunque, ResNet fornisce già un'ottima ricostruzione dei modelli.

Simili problematiche e risultati sono dati dalle ricostruzioni dei modelli SIRS attraverso Universal Differential Equations.

Anche in questo caso i MSE sono buoni, seppur maggiori rispetto a quelli delle ResNet.

Tuttavia, mentre nel primo modello sono visibili oscillazioni in quantità maggiore, ma di ampiezza minore, rispetto ai dati reali, nel secondo modello le oscillazioni non sono proprio presenti.

Un aspetto cruciale emerso durante l'addestramento è stato la sensibilità dell'ottimizzatore ADAM al parametro di learning rate, aggiustato e corretto più volte.

Per quanto riguarda le NeuralODE, invece, il discorso è molto diverso. In entrambi i modelli le reti non imparano le dinamiche oscillatorie, di fatto “tagliando dritto”. Questo fattore comporta un MSE 10 volte maggiore a quello della ResNet per quanto riguarda il modello SIRS con $R_0 = 2$, mentre nel secondo caso l'aumento è addirittura di circa 1000 volte.

La maggiore difficoltà riscontrata durante l'allenamento è data dall'elevata sensibilità dei metodi di solver. L'utilizzo del solver Rodas5, meno sensibile a ODE *stiff*, cioè con parametri operanti su scale temporali diverse (in questo caso, $\gamma \gg \mu$), non ha portato a risultati migliori.

Una parziale spiegazione delle pessime performance delle Neural ODE può essere data dall'utilizzo di una rete molto piccola per la risoluzio-




Figura 6.3.3: L’andamento della classe degli infetti nei due modelli SIRS considerati, con errore gaussiano. Si noti come le ampiezze del rumore sembrano diverse a causa della diversa scala verticale dei grafici.

ne. Tuttavia, il tempo di addestramento di reti neurali più profonde è risultato incompatibile con i tempi di stesura della tesi.

Dati con rumore Il secondo passo nello studio dei metodi di ricostruzione del modello SIRS ha riguardato l’analisi dei modelli con dati sporcati tramite rumore ottenuto da una normale $\mathcal{N}(0, 1)$ moltiplicato per 0.005 al fine di uniformare le dimensioni.

Come è lecito aspettarsi, i risultati della ricostruzione sono stati in genere peggiori rispetto a quelli ottenuti partendo da dati non sporcati, come testimoniato dalle loss nella Tabella 6.3.3 maggiori di un fattore $10x$ rispetto alle controparti illustrate precedentemente.

Le criticità emerse sono simili a quelle già discusse nel caso precedente, con i modelli che in genere preferiscono “tagliare” le oscillazioni assestandosi molto velocemente attorno al valore dell’equilibrio. Anche in questo caso, l’unica architettura che mantiene la dinamica del modello è quella delle ResNet.

In conclusione, i risultati di questi esperimenti non sono stati soddisfacenti. Nonostante diverse prove effettuate, ciascuna con diversi iperparametri e solver, le architetture sembrano in grado di ricostruire solo approssimativamente le dinamiche dei modelli presentati. In particolare, le oscillazioni sistematicamente non vengono imparate, e




Figura 6.3.4: Le ricostruzioni delle diverse architetture dei due modelli SIRS considerati, a sinistra il caso con $R_0 = 2$ e a destra il caso con $R_0 = 10$. In entrambi i pannelli, in azzurro i dati di addestramento; in rosso le ricostruzioni delle ResNet, in verde quelle delle Neural ODE e in arancio quelle delle UDE.

Architettura	$R_0 = 2$	$R_0 = 10$
ResNet	0.043396	0.001262
Neural ODE	0.005978	0.000509
UDE	0.004557	0.002178

Tabella 6.3.3: Valori di $loss$ per le tre architetture nel caso SIRS con $R_0 = 2$ e $R_0 = 10$, ricostruendo a partire da dati con errore gaussiano

nella gran parte dei casi si assiste a fenomeni di instabilità dei risultati con frequenti underflow a livello computazionale.

I risultati sono quindi ben diversi da quelli ottenuti nei già citati paper di riferimento ([25], [28], [31]), e sollevano qualche dubbio circa la genericità di queste architetture.

Va altresì detto come esista una grande varietà di combinazioni di algoritmi di soluzione di ODE e di ottimizzatori ancora non esplorata, e che pertanto le soluzioni raggiunte non sono certamente definitive.

Capitolo 7

Discussione e sviluppi futuri

Nella presente tesi è stato introdotto e analizzato un nuovo modello nell'ambito dell'epidemiologia comportamentale, il modello SIRS con distanziamento sociale.

Sono state considerate diverse varianti dello stesso, ciascuna differente nelle modalità di implementazione del concetto di *informazione* e di *memoria*; in particolare, sono stati costruiti i modelli SIRS con solo l'informazione corrente, con memoria basata sull'incidenza o sulla prevalenza, attraverso uno o due layer. Infine, è stato velocemente discusso anche il caso senza dinamica vitale.

A partire dalle successive analisi, si è riscontrato come i diversi modelli presentino, come il modello SIRS classico, due punti di equilibrio, uno di tipo *disease-free* ed uno endemico.

Interessante è stata la discussione circa la stabilità di questo secondo equilibrio, che ha necessitato, per quanto riguarda i modelli con memoria *incidence-based*, l'utilizzo di simulazioni al computer.

In ogni caso, si è giunti alla conferma dell'effettiva stabilità globale dell'equilibrio endemico per valori di $R_0 > 1$.

Successive simulazioni hanno poi interessato l'effettivo impatto della misura del distanziamento sociale, riscontrando una diminuzione nell'incidenza cumulativa complessiva minore rispetto al modello SIRS classico, con un impatto variabile a seconda dell'importanza data all'informazione. In ogni caso, comunque, si è riscontrato come, a prescindere dal peso del distanziamento sociale, questo non sia in grado di eradicare l'epidemia, ma solo di rallentarne e contenerne la diffusione.

Sono state, infine, sfruttate 3 diverse architetture di machine learning, quali le Residual Networks, le Neural Ordinary Differential Equations e le Universal Differential Equations, al fine di ricostruire le dinamiche del modello SIRS. I risultati ottenuti, poco incoraggianti, denunciano un'elevata sensibilità delle tecniche di ricostruzione utilizzate e una generale, effettiva incapacità di identificazione e di ricostruzione dei fenomeni di oscillazione tipici del modello SIRS.

Quest'ultimo aspetto risulta comunque degno di un maggiore studio, che sfrutti implementazioni più profonde delle reti neurali e analizzi in maggiore dettaglio gli iperparametri e i risolutori di equazioni differenziali migliori per il caso in questione.

Interessante è anche la possibilità di estendere l'analisi dell'impatto di misure comportamentali in altri modelli epidemiologici classici, che tengano conto, per esempio, anche dei tassi di mortalità della malattia e dei tassi di vaccinazione.

Bibliografia

- [1] William Ogilvy Kermack and Anderson G McKendrick. A contribution to the mathematical theory of epidemics. *Proceedings of the royal society of london. Series A, Containing papers of a mathematical and physical character*, 115(772):700–721, 1927.
- [2] Ronald Ross. An application of the theory of probabilities to the study of a priori pathometry. *Proceedings of the Royal Society of London. Series A, Containing papers of a mathematical and physical character*, 92(638):204–230, 1916.
- [3] Matt J. Keeling and Pejman Rohani. *Modeling infectious diseases in humans and animals*. Princeton university press, 2008.
- [4] Hamish McCallum, Nigel Barlow, and Jim Hone. How should pathogen transmission be modelled? *Trends in ecology & evolution*, 16(6):295–300, 2001.
- [5] Michael Begon, Malcolm Bennett, Roger G. Bowers, Nigel P. French, S.M. Hazel, and Joseph Turner. A clarification of transmission terms in host-microparasite models: numbers, densities and areas. *Epidemiology & Infection*, 129(1):147–153, 2002.
- [6] Michael Y. Li and James S. Muldowney. Global stability for the seir model in epidemiology. *Mathematical biosciences*, 125(2):155–164, 1995.
- [7] Nicholas C. Grassly, Christophe Fraser, and Geoffrey P. Garnett. Host immunity and synchronized epidemics of syphilis across the united states. *Nature*, 433(7024):417–421, 2005.
- [8] Zhen Wang, Chris T. Bauch, Samit Bhattacharyya, Alberto d’Onofrio, Piero Manfredi, Matjaž Perc, Nicola Perra, Marcel Salathé, and Dawei Zhao. Statistical physics of vaccination. *Physics Reports*, 664:1–113, 2016.

- [9] Vincenzo Capasso and Gabriella Serio. A generalization of the kermack-mckendrick deterministic epidemic model. *Mathematical biosciences*, 42(1-2):43–61, 1978.
- [10] Chris T. Bauch and Samit Bhattacharyya. Evolutionary game theory and social learning can determine how vaccine scares unfold. *PLoS computational biology*, 8(4):e1002452, 2012.
- [11] Timothy C. Reluga, Chris T. Bauch, and Alison P. Galvani. Evolving public perceptions and stability in vaccine uptake. *Mathematical biosciences*, 204(2):185–198, 2006.
- [12] Robert May. Simple rules with complex dynamics. *Science*, 287:601–602, 01 2000.
- [13] Piero Manfredi and Alberto d’Onofrio. *Modeling the interplay between human behavior and the spread of infectious diseases*. Springer Science & Business Media, 2013.
- [14] Feng Fu, Daniel I. Rosenbloom, Long Wang, and Martin A. Nowak. Imitation dynamics of vaccination behaviour on social networks. *Proceedings of the Royal Society B: Biological Sciences*, 278(1702):42–49, 2011.
- [15] Paul Erdos and Alfred Rényi. On random graphs 1. *Publicationes Mathematicae Debrecen*, 6(290-297):18, 1959.
- [16] Lee-Ann Barlow, Jacob Cecile, Chris T. Bauch, and Madhur Anand. Modelling interactions between forest pest invasions and human decisions regarding firewood transport restrictions. *PLOS One*, 9(4), 2014.
- [17] Alberto d’Onofrio and Piero Manfredi. Behavioral sir models with incidence-based social-distancing. *Chaos, Solitons & Fractals*, 159:112072, 2022.
- [18] Norman MacDonald. *Biological delay systems: linear stability theory*. Cambridge University Press, 1989.
- [19] Alberto d’Onofrio, Piero Manfredi, and Ernesto Salinelli. Vaccinating behaviour, information, and the dynamics of sir vaccine preventable diseases. *Theoretical population biology*, 71(3):301–317, 2007.

- [20] Alberto d’Onofrio, Piero Manfredi, and Ernesto Salinelli. Vaccinating behaviour and the dynamics of vaccine preventable infections. In *Modeling the Interplay Between Human Behavior and the Spread of Infectious Diseases*, pages 267–287. Springer, 2012.
- [21] Miklós Farkas. *Periodic Motions*, volume 104. Springer Science & Business Media, 1994.
- [22] Vincenzo Capasso, Enea Grosso, and Gabriella Serio. I modelli matematici nella indagine epidemiologica. i. applicazione all’epidemia di colera verificatesi in bari nel 1973. *Annali Sclavo*, (19):193–208, 1977.
- [23] Vincenzo Capasso and S.L. Paveri-Fontana. A mathematical model for the 1973 cholera epidemic in the european mediterranean region. *Revue d’épidemiologie et de sante publique*, 27(2):121–132, 1979.
- [24] Horst R. Thieme. *Mathematics in population biology*. Princeton University Press, 2018.
- [25] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [26] Yoshua Bengio, Patrice Simard, and Paolo Frasconi. Learning long-term dependencies with gradient descent is difficult. *IEEE transactions on neural networks*, 5(2):157–166, 1994.
- [27] Xavier Glorot and Yoshua Bengio. Understanding the difficulty of training deep feedforward neural networks. In *Proceedings of the thirteenth international conference on artificial intelligence and statistics*, pages 249–256. JMLR Workshop and Conference Proceedings, 2010.
- [28] Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David K. Duvenaud. Neural ordinary differential equations. *Advances in neural information processing systems*, 31, 2018.
- [29] Yiping Lu, Aoxiao Zhong, Quanzheng Li, and Bin Dong. Beyond finite layer neural networks: Bridging deep architectures and

numerical differential equations. In *International conference on machine learning*, pages 3276–3285. PMLR, 2018.

- [30] Lev Semenovich Pontryagin. *Mathematical theory of optimal processes*. Routledge, 1962.
- [31] Christopher Rackauckas, Yingbo Ma, Julius Martensen, Collin Warner, Kirill Zubov, Rohit Supekar, Dominic Skinner, Ali Ramadhan, and Alan Edelman. Universal differential equations for scientific machine learning. *arXiv preprint arXiv:2001.04385*, 2020.